



**Universidad  
Europea**

**UNIVERSIDAD EUROPEA DE MADRID**

**ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO**

**MÁSTER UNIVERSITARIO EN ANÁLISIS DE DATOS MASIVOS  
(BIG DATA)**

**TRABAJO FIN DE MÁSTER**

**ANÁLISIS A GRAN ESCALA DE LA  
ROBUSTEZ DE MÉTRICAS DE SIMILITUD  
ESPECTRAL FRENTE A LA DEGRADACIÓN  
DE CALIDAD PARA LA IDENTIFICACIÓN DE  
MICROPLÁSTICOS**

**JESÚS BAEZA ANGUIANO**

**Dirigido por**

**Nico Coca López**

**CURSO 2025 - 2026**

---

**TÍTULO:** ANÁLISIS A GRAN ESCALA DE LA ROBUSTEZ DE MÉTRICAS DE SIMILITUD ESPECTRAL FRENTE A LA DEGRADACIÓN DE CALIDAD PARA LA IDENTIFICACIÓN DE MICROPLÁSTICOS

**AUTOR:** JESÚS BAEZA ANGUIANO

**TITULACIÓN:** MÁSTER UNIVERSITARIO EN ANÁLISIS DE DATOS MASIVOS (BIG DATA)

**DIRECTOR DEL PROYECTO:** Nico Coca López

**FECHA:** Septiembre de 2026

## RESUMEN

Los microplásticos son ya un contaminante ubicuo en agua, suelo y aire, y su identificación fiable sigue siendo un problema abierto. La espectroscopía Raman identifica el polímero de una partícula comparando su espectro con bibliotecas de referencia, pero la calidad de esa medida depende del tiempo de integración, y el comportamiento de las métricas de similitud frente a esa pérdida de calidad no se ha evaluado sistemáticamente y a escala.

Este trabajo desarrolla un *pipeline* reproducible y paralelizable con Apache Spark que cuantifica la robustez de siete métricas de similitud (coseno, Pearson, Spearman, *Spectral Angle Mapper* (SAM), *Hit Quality Index* (HQI), euclídea y Manhattan) frente a dos mecanismos independientes: la acumulación de espectros reales de integración corta y una degradación paramétrica por ruido. El preprocesado reproduce sin diferencia numérica el protocolo de referencia del director.

Ejecutado sobre cinco polímeros y una biblioteca pública de treinta espectros, el experimento muestra que Pearson es la métrica más robusta frente a la degradación real por acumulación (61,5 % de aciertos), mientras que coseno, euclídea, HQI y SAM lo son frente a la paramétrica (87,5 %); Manhattan y Spearman quedan las últimas en los dos ejes. Ninguna diferencia es significativa por pares tras corregir por comparaciones múltiples, de modo que la métrica idónea depende del mecanismo de pérdida de calidad. Se detectó además que la biblioteca no cubre dos de los cinco polímeros medidos, limitación de cobertura que condiciona cualquier identificación.

**Palabras clave:** Big Data, Apache Spark, espectroscopía Raman, microplásticos, métricas de similitud espectral, relación señal-ruido.

## ABSTRACT

Microplastics are now a ubiquitous contaminant in water, soil and air, and identifying them reliably remains an open problem. Raman spectroscopy identifies a particle's polymer by matching its spectrum against reference libraries, but the quality of that measurement depends on integration time, and the behaviour of similarity metrics under such quality loss has not been evaluated systematically and at scale.

This work develops a reproducible, Spark-parallelised pipeline that quantifies the robustness of seven similarity metrics (cosine, Pearson, Spearman, Spectral Angle Mapper (SAM), Hit Quality Index (HQI), Euclidean and Manhattan) against two independent mechanisms: the accumulation of real short-integration-time spectra, and a parametric noise-based degradation. Preprocessing reproduces the supervisor's reference protocol with zero numerical difference.

Run on five polymers and a public library of thirty reference spectra, the experiment shows that Pearson is the most robust metric against real accumulation-driven degradation (61.5 % accuracy), whereas cosine, Euclidean, HQI and SAM are the most robust against parametric degradation (87.5 %); Manhattan and Spearman are consistently the least robust. No pairwise difference is significant after correcting for multiple comparisons, so the most suitable metric depends on the specific quality-loss mechanism. The reference library was also found not to cover two of the five measured polymers, a coverage limitation that constrains any identification.

**Keywords:** Big Data, Apache Spark, Raman spectroscopy, microplastics, spectral similarity metrics, signal-to-noise ratio.

# Índice general

|                                                                        |           |
|------------------------------------------------------------------------|-----------|
| <b>RESUMEN</b>                                                         | <b>2</b>  |
| <b>ABSTRACT</b>                                                        | <b>3</b>  |
| <b>1. RESUMEN DEL PROYECTO</b>                                         | <b>8</b>  |
| 1.1. Contexto y justificación                                          | 8         |
| 1.2. Planteamiento del problema                                        | 8         |
| 1.3. Objetivos del proyecto                                            | 8         |
| 1.4. Resultados obtenidos                                              | 8         |
| 1.5. Estructura de la memoria                                          | 8         |
| <b>2. ANTECEDENTES / ESTADO DEL ARTE</b>                               | <b>9</b>  |
| 2.1. Estado del arte                                                   | 9         |
| 2.1.1. Contaminación por microplásticos y retos analíticos             | 9         |
| 2.1.2. Herramientas y bases de datos <i>open-source</i> de referencia  | 9         |
| 2.1.3. Métricas de similitud espectral                                 | 10        |
| 2.1.4. Tecnologías de procesamiento a gran escala                      | 10        |
| 2.2. Contexto y justificación                                          | 10        |
| 2.3. Planteamiento del problema                                        | 11        |
| <b>3. OBJETIVOS</b>                                                    | <b>12</b> |
| 3.1. Objetivo general                                                  | 12        |
| 3.2. Objetivos específicos                                             | 12        |
| 3.3. Alcance y fuera del alcance                                       | 13        |
| 3.4. Beneficios del proyecto                                           | 13        |
| <b>4. DESARROLLO DEL PROYECTO</b>                                      | <b>15</b> |
| 4.1. Planificación del proyecto                                        | 15        |
| 4.2. Descripción de la solución, metodologías y herramientas empleadas | 16        |
| 4.2.1. Visión general del pipeline                                     | 16        |
| 4.2.2. Pipeline de preprocesado                                        | 16        |
| 4.2.3. Métricas de similitud espectral                                 | 17        |
| 4.2.4. Protocolo de matching                                           | 17        |
| 4.2.5. Arquitectura Big Data                                           | 18        |
| 4.2.6. Análisis estadístico                                            | 18        |
| 4.2.7. Decisiones técnicas y su justificación                          | 18        |
| 4.2.8. Metodología de trabajo                                          | 19        |
| 4.2.9. Datos del proyecto                                              | 19        |
| 4.3. Recursos requeridos                                               | 20        |
| 4.4. Presupuesto                                                       | 20        |
| 4.5. Viabilidad                                                        | 21        |
| 4.6. Sostenibilidad del proyecto                                       | 21        |

---

|                                                            |           |
|------------------------------------------------------------|-----------|
| 4.7. Resultados del proyecto . . . . .                     | 23        |
| 4.7.1. Resultados obtenidos . . . . .                      | 24        |
| <b>5. DISCUSIÓN</b>                                        | <b>30</b> |
| 5.1. Adecuación de la metodología al problema . . . . .    | 30        |
| 5.2. Cambios respecto al planteamiento inicial . . . . .   | 30        |
| 5.3. Limitaciones identificadas . . . . .                  | 30        |
| 5.4. Interpretación de los primeros resultados . . . . .   | 31        |
| 5.5. Impacto esperado . . . . .                            | 31        |
| <b>6. CONCLUSIONES</b>                                     | <b>32</b> |
| 6.1. Conclusiones del trabajo . . . . .                    | 32        |
| 6.2. Conclusiones personales . . . . .                     | 32        |
| <b>7. FUTURAS LÍNEAS DE TRABAJO</b>                        | <b>35</b> |
| <b>8. REFERENCIAS</b>                                      | <b>36</b> |
| <b>REFERENCIAS</b>                                         | <b>36</b> |
| <b>9. ANEXOS</b>                                           | <b>38</b> |
| Anexo A. Estructura del repositorio de código . . . . .    | 38        |
| Anexo B. Reproducibilidad e integración continua . . . . . | 38        |
| Anexo C. Repositorio de la memoria . . . . .               | 39        |

## Índice de Figuras

|                                                                                                                                                                                                                                    |    |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.1. Cronograma del proyecto con sus hitos de entrega. La Fase 3, incluida la ejecución del experimento con datos reales, se completó antes de la entrega intermedia. . . . .                                                      | 16 |
| 4.2. Flujo del <i>pipeline</i> implementado en el paquete <i>microraman</i> . . . . .                                                                                                                                              | 16 |
| 4.3. Similitud del mejor resultado (rango 1) frente al número de acumulaciones, una curva por métrica, una subgráfica por polímero medido. La cruz roja marca el punto en que el rango 1 deja de ser el polímero correcto. . . . . | 25 |
| 4.4. Punto de ruptura por métrica y polímero en el eje de acumulación. Las celdas vacías indican que esa métrica nunca identifica correctamente ese polímero de forma estable. . . . .                                             | 26 |
| 4.5. Similitud del mejor resultado (rango 1) frente a la SNR de la degradación paramétrica, una curva por métrica y una subgráfica por polímero medido. . . . .                                                                    | 28 |
| 4.6. Punto de ruptura por métrica y polímero en el eje de degradación paramétrica, expresado como SNR mínima para un acierto estable. . . . .                                                                                      | 29 |

## Índice de Tablas

|                                                                                                                                                                                                                                                                              |    |
|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 4.1. Fases del proyecto, objetivos específicos asociados y esfuerzo estimado. . . . .                                                                                                                                                                                        | 15 |
| 4.2. Decisiones técnicas clave del proyecto, tras el pivote de diseño (ADR-004), y su justificación. . . . .                                                                                                                                                                 | 19 |
| 4.3. Estimación del presupuesto del proyecto. . . . .                                                                                                                                                                                                                        | 21 |
| 4.4. Exactitud de cada métrica de similitud (PET/PLA/PP), por eje de degradación de calidad. . . . .                                                                                                                                                                         | 24 |
| 4.5. Punto de ruptura por métrica y eje de degradación de calidad. Un valor menor indica que la métrica tolera más degradación antes de fallar; la última columna indica sobre cuántos de los cinco polímeros medidos la métrica no llega a acertar en ningún nivel. . . . . | 26 |

# Capítulo 1. RESUMEN DEL PROYECTO

## 1.1 Contexto y justificación

La contaminación por microplásticos es un desafío medioambiental global, y la espectroscopía Raman es hoy la técnica habitual para identificar el polímero de una partícula por comparación con bibliotecas espectrales (*matching*). La calidad del espectro medido depende directamente del tiempo de integración: un tiempo corto, deseable para aumentar el rendimiento de muestreo, produce espectros ruidosos y más difíciles de identificar. El comportamiento de las distintas métricas de similitud frente a esa degradación rara vez se compara de forma sistemática.

## 1.2 Planteamiento del problema

¿Cómo se degrada el *matching* de un espectro Raman de microplástico contra una base de datos de referencia a medida que empeora la calidad de la señal, y qué métrica de similitud es más robusta frente a esa degradación? El proyecto tiene dos mitades: caracterizar empíricamente cómo se comportan siete métricas frente al ruido, y construir el *pipeline* que lo hace posible, con preprocesado, *matching* y análisis estadístico, reproducible y paralelizable con Apache Spark.

## 1.3 Objetivos del proyecto

El objetivo general es evaluar a gran escala la robustez de distintas métricas de similitud espectral frente a la degradación de la calidad del espectro Raman, implementando un *pipeline* reproducible y paralelizable. Los objetivos específicos se detallan en el Capítulo 3: validar el preprocesado contra el protocolo de referencia, implementar las siete métricas, diseñar y paralelizar la matriz experimental, medir la robustez con el punto de ruptura y un análisis estadístico, y generar el entregable visual.

## 1.4 Resultados obtenidos

El *pipeline* reproduce el protocolo de referencia con diferencia numérica nula y el experimento se ha ejecutado completo sobre cinco polímeros y la biblioteca pública *Hagelskjær Microplastic Solution Library 1.1*, superando la validación numérica acordada (1885 comparaciones alineadas). Pearson aguanta mejor la acumulación real (61,5% de aciertos); con la degradación paramétrica el mejor grupo es otro, el de coseno, euclídea, HQI y SAM (87,5%). Manhattan y Spearman quedan por debajo en los dos ejes, y ninguna diferencia por pares sobrevive la corrección de Holm. Se detectó además que la biblioteca de referencia no cubre dos de los cinco polímeros medidos.

## 1.5 Estructura de la memoria

La memoria se organiza en nueve capítulos. El Capítulo 2 presenta los antecedentes y el estado del arte; el Capítulo 3 detalla los objetivos; el Capítulo 4, núcleo del documento, describe la planificación, el *pipeline*, las decisiones técnicas y los resultados; el Capítulo 5 discute limitaciones y adaptaciones; los Capítulos 6 y 7 recogen conclusiones y futuras líneas de trabajo; los Capítulos 8 y 9, las referencias bibliográficas y los anexos técnicos.

## Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

Antes de plantear la pregunta de investigación conviene situar los fundamentos de la clasificación espectral de microplásticos, las herramientas y bases de datos *open-source* existentes, las métricas de similitud espectral empleadas habitualmente en este dominio, y las tecnologías de procesamiento a gran escala sobre las que se apoya la implementación. La revisión establece la base sobre la que se identifica la pregunta de investigación que el TFM pretende responder.

### 2.1 Estado del arte

#### 2.1.1. Contaminación por microplásticos y retos analíticos

Los microplásticos, definidos como partículas plásticas de tamaño inferior a 5 mm, constituyen un contaminante ubicuo en ecosistemas marinos, fluviales, terrestres y atmosféricos (Cole et al., 2011). Su persistencia y su potencial transferencia a la cadena trófica y al organismo humano (Hernández et al., 2017) han impulsado el desarrollo de métodos analíticos capaces de identificar el tipo de polímero con precisión. Las dos técnicas espectroscópicas dominantes son la espectroscopía Raman y la espectroscopía FTIR, ambas capaces de generar huellas espectrales características de cada polímero (Araújo et al., 2018; Schymanski et al., 2021). Un reto práctico compartido por ambas técnicas es que la calidad de la señal depende directamente del tiempo de integración del instrumento: un tiempo de integración corto, deseable para aumentar el rendimiento de muestreo, produce espectros con menor relación señal/ruido (SNR) y, por tanto, más difíciles de identificar correctamente.

#### 2.1.2. Herramientas y bases de datos *open-source* de referencia

Entre las herramientas *open-source* para la identificación de microplásticos, Open Specy es hoy la plataforma comunitaria más usada (Cowger et al., 2021). En su versión 1.0, Open Specy integra una biblioteca de más de 40.000 espectros de referencia procedentes de repositorios como RRUFF y la Raman Open Database, junto con clasificadores basados en aprendizaje automático (K-medoids y regresión logística) que alcanzan en torno al 96 % de precisión sobre su conjunto derivado (Cowger et al., 2025). siMPle (Pimpke et al., 2020) es un software independiente orientado al análisis sistemático de espectros FTIR de microplásticos, y las bases de datos de referencia como la de Pimpke et al. (2018) aportan bibliotecas espectrales curadas que complementan estos esfuerzos.

Para el presente TFM, la base de datos de referencia empleada en el *matching* es la *Hagelskjær Microplastic Solution Library 1.1* (Hagelskjær et al., 2025), de acceso público en Zenodo bajo licencia CC-BY-4.0, que se compone de 30 espectros de referencia (28 polímeros y 2 minerales) en formato de texto plano.

### 2.1.3. Métricas de similitud espectral

La comparación entre un espectro medido y una biblioteca de referencia requiere una métrica de similitud (o distancia, transformada a similitud) que cuantifique el parecido entre ambos vectores de intensidad. En la práctica de la espectroscopía analítica y del procesamiento de señal se emplean, entre otras, la correlación de Pearson y su variante no paramétrica de Spearman, la similitud coseno y su transformación angular (*Spectral Angle Mapper*, SAM), el *Hit Quality Index* (HQI, equivalente al cuadrado de la similitud coseno y de uso extendido en librerías comerciales de espectroscopía), y las distancias  $L_1$  (Manhattan) y  $L_2$  (euclídea) sobre vectores normalizados. No hay consenso sobre qué métrica es preferible: su comportamiento relativo depende del tipo de degradación de la señal. Falta, por tanto, una comparación empírica que lo mida.

### 2.1.4. Tecnologías de procesamiento a gran escala

El paradigma Big Data ofrece mecanismos probados para el procesamiento distribuido de grandes volúmenes de datos, cuyo origen se remonta al modelo *MapReduce* (Dean & Ghemawat, 2004), que popularizó la descomposición de un cómputo masivo en tareas independientes distribuidas sobre un clúster de nodos sin memoria compartida. Apache Spark (Zaharia et al., 2010, 2016) extendió ese paradigma introduciendo el concepto de *Resilient Distributed Dataset* (RDD) y, posteriormente, las abstracciones *DataFrame* y *Dataset* (Armbrust et al., 2015), con las que las operaciones en memoria son mucho más rápidas que los motores basados en disco para cargas iterativas. Su API en Python (PySpark) paraleliza operaciones vectorizadas de forma directa. Este mismo paradigma de cómputo distribuido por clúster se ha aplicado con éxito a otros dominios científicos con una estructura de datos análoga a la de este TFM: por ejemplo, Freeman et al. (2014) emplean cómputo distribuido para mapear a escala la actividad cerebral del pez cebra a partir de volúmenes masivos de imágenes, con una carga descomponible en bloques independientes de forma directa. El problema abordado en este TFM encaja en ese mismo patrón, ya que la carga computacional proviene de una combinatoria de comparaciones (polímero  $\times$  nivel de calidad  $\times$  métrica  $\times$  espectro de referencia) fácilmente paralelizable por bloques independientes.

## 2.2 Contexto y justificación

El comportamiento de las métricas de similitud espectral frente al ruido no suele evaluarse de forma sistemática y a escala: los estudios que emplean una métrica concreta rara vez justifican esa elección frente a las alternativas, ni cuantifican en qué punto de degradación de la señal deja de ser fiable. Esta ausencia de una comparación empírica y reproducible es la brecha que aborda este TFM: no se trata de proponer una nueva técnica de clasificación espectral ni de mejorar una herramienta existente, sino de generar evidencia empírica, a partir de datos reales y de una matriz experimental de gran volumen, sobre qué métrica de similitud es más robusta frente a la pérdida de calidad de la señal, y de hacerlo con un *pipeline* paralelizable que permita repetir el análisis sobre bases de datos de referencia más amplias sin rediseñar el proceso.

## 2.3 Planteamiento del problema

A partir de la revisión anterior, la pregunta de investigación puede formularse en los siguientes términos:

*¿Cómo se degrada el resultado del matching de un espectro Raman de microplástico contra una base de datos de referencia a medida que empeora la calidad de la señal medida (relación señal/ruido), y qué métrica de similitud espectral es más robusta frente a esa degradación?*

Este planteamiento orienta las decisiones técnicas del proyecto: el uso de la acumulación de espectros de integración corta como mecanismo controlado para variar la SNR, la implementación de un conjunto amplio de métricas de similitud bajo una convención homogénea, la paralelización del cómputo combinatorio con Apache Spark, y un diseño estadístico de medidas repetidas (Friedman y post-hoc de Wilcoxon con corrección de Holm–Bonferroni) que permita determinar si las diferencias observadas entre métricas son estadísticamente significativas y no atribuibles al azar.

## Capítulo 3. OBJETIVOS

El objetivo general fija qué aporta el proyecto; los cinco objetivos específicos (OE1–OE5) organizan el trabajo técnico y se usan como referencia a lo largo del Capítulo 4. El capítulo termina delimitando el alcance y los beneficios esperados.

### 3.1 Objetivo general

El objetivo general del presente Trabajo Fin de Máster consiste en **evaluar a gran escala la robustez de distintas métricas de similitud espectral frente a la degradación de la calidad del espectro Raman en la identificación de microplásticos, e implementar para ello un *pipeline* reproducible y paralelizable** que permita ejecutar dicha evaluación sobre el volumen combinatorio de comparaciones que exige el problema (polímeros  $\times$  niveles de calidad  $\times$  métricas  $\times$  espectros de referencia).

El proyecto tiene dos mitades. Una es investigación aplicada: caracterizar empíricamente cómo se comportan siete métricas de similitud frente al ruido espectral. La otra es ingeniería de datos: construir el *pipeline* de preprocesado, *matching* y análisis estadístico, validado y paralelizable con Apache Spark.

### 3.2 Objetivos específicos

Los objetivos específicos derivan del objetivo general y han servido de guía para organizar las fases del proyecto. La numeración **OE1–OE5** se utiliza de forma transversal en el Capítulo 4 para rastrear la correspondencia entre tareas, código y objetivos.

- **OE1. Implementar y validar un *pipeline* de preprocesado espectral** (recorte por índice, eliminación de picos espurios, acumulación por suma y corrección de línea base) equivalente al protocolo de referencia definido por el director del proyecto, y verificar dicha equivalencia de forma numérica sobre los espectros reales.
- **OE2. Implementar un conjunto de al menos siete métricas de similitud** espectral como funciones reutilizables y vectorizables, con una convención homogénea en la que un valor mayor siempre indica mayor parecido, con independencia de si la métrica original es una similitud o una distancia.
- **OE3. Diseñar y ejecutar la matriz experimental** (polímero  $\times$  nivel de acumulación  $\times$  métrica  $\times$  espectro de la base de datos de referencia) y paralelizar su cómputo con Apache Spark, verificando la equivalencia entre el motor de referencia (*pandas/NumPy*) y el motor distribuido.
- **OE4. Cuantificar la robustez de cada métrica** frente a la degradación de la calidad espectral mediante el concepto de *punto de ruptura* (el número mínimo de acumulaciones a partir del cual el primer resultado del *matching* es el polímero correcto de forma estable) y un análisis estadístico de las diferencias entre métricas (test de Friedman, tamaño del efecto y comparaciones post-hoc por pares).
- **OE5. Producir el entregable visual solicitado por el director del proyecto** (similitud del mejor resultado frente al nivel de acumulación, con una curva por métrica y por polímero) y derivar de él una guía empírica de qué métrica conviene emplear según la calidad esperada del espectro.

### 3.3 Alcance y fuera del alcance

La dedicación prevista de 300 horas obligó a acotar el alcance desde el principio. **Se incluye:**

- La implementación y validación numérica del *pipeline* de preprocesado frente al protocolo de referencia del director del proyecto.
- La implementación de las siete métricas de similitud y del motor de *matching*, en su versión de referencia (*pandas*) y en su versión distribuida (PySpark).
- El diseño de la matriz experimental completa y del análisis estadístico asociado (test de Friedman, tamaño del efecto de Kendall y post-hoc de Wilcoxon con corrección de Holm–Bonferroni).
- Un mecanismo de comprobación cruzada mediante degradación controlada de la señal (ruido, deriva de línea base y submuestreo) como segundo eje de calidad independiente de la acumulación.
- La ejecución del experimento completo y la generación del entregable visual, ya realizada con la base de datos de referencia real (Hagelskjær Microplastic Solution Library 1.1, de acceso público).

**Queda fuera del alcance**, por las razones justificadas en el anteproyecto aprobado y en el diseño experimental acordado con el director:

- El desarrollo de nuevas métricas de similitud. Se comparan siete métricas ya establecidas en la literatura y en la práctica de la espectroscopía analítica, no se propone ninguna nueva.
- El entrenamiento de modelos de aprendizaje automático para la clasificación espectral. El proyecto compara métricas de similitud directa, no clasificadores entrenados.
- El despliegue en infraestructura distribuida real (*cluster* multi-nodo o *cloud*). La paralelización con Apache Spark se valida en un entorno local; el despliegue distribuido físico se plantea como trabajo futuro.

### 3.4 Beneficios del proyecto

El proyecto aporta beneficios tanto a la comunidad científica dedicada al análisis de microplásticos como al ámbito de la ingeniería de datos aplicada a la química analítica:

- **Guía empírica y reproducible** sobre qué métrica de similitud espectral resulta más robusta frente a la degradación de la calidad de la señal, útil para quien deba decidir un criterio de *matching* en condiciones de tiempo de integración limitado.
- **Pipeline validado y reutilizable**, verificado contra el protocolo de referencia sin diferencia numérica. Se aplica tal cual a otros conjuntos de espectros Raman de microplásticos.
- **Escalado horizontal del cómputo de similitud**, mediante una implementación en Apache Spark equivalente y verificada frente a la referencia en *pandas*, que permite extender el análisis a bases de datos de referencia de mayor tamaño sin rediseñar el *pipeline*.
- **Comprobación cruzada metodológica**. El análisis se repite con un segundo mecanismo de degradación, independiente de la acumulación real. Si el *ranking* coincide, no es un artefacto del mecanismo.

- 
- **Valor metodológico y docente:** el proyecto sirve como caso de estudio de aplicación de tecnologías de procesamiento a gran escala a un problema científico concreto, con un diseño experimental y estadístico documentado y reproducible.

## Capítulo 4. DESARROLLO DEL PROYECTO

Este capítulo recoge el desarrollo técnico del proyecto: la planificación real, el *pipeline* implementado y las decisiones que lo sustentan, los recursos y el presupuesto, la viabilidad, la sostenibilidad y los resultados obtenidos.


### 4.1 Planificación del proyecto

La planificación parte de la estructura en cuatro fases aprobada en el anteproyecto, con una dedicación estimada total de 300 horas. Tras el pivote de diseño documentado en el ADR-004 (véase el apartado de decisiones técnicas), el contenido de cada fase se reformuló en torno al nuevo experimento de robustez de métricas, pero la estructura temporal se mantuvo. La Tabla 4.1 resume las fases, su vinculación con los objetivos específicos (OE) y el esfuerzo asignado.

| Fase                                                                    | OE                  | Tareas principales                                                                                                                                     | Horas |
|-------------------------------------------------------------------------|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|-------|
| Fase 1. Análisis y estado del arte (abril–mayo 2026)                    | OE1                 | Revisión bibliográfica, análisis de Open Specy, selección de <i>stack</i> , definición del protocolo de referencia junto con el director               | 40    |
| Fase 2. Diseño e implementación (mayo–agosto 2026)                      | OE1,<br>OE2,<br>OE3 | Reconstrucción del <i>pipeline</i> de preprocesado, implementación de las siete métricas, motor de <i>matching</i> pandas/Spark, suite de pruebas y CI | 120   |
| Fase 3. Ejecución del experimento y validación (agosto–septiembre 2026) | OE3,<br>OE4,<br>OE5 | Ejecución de la matriz experimental completa con la base de datos de referencia, análisis estadístico, entregable visual                               | 60    |
| Fase 4. Redacción y cierre (agosto–septiembre 2026)                     | —                   | Redacción de memoria, revisión, defensa                                                                                                                | 80    |

**Tabla 4.1.** Fases del proyecto, objetivos específicos asociados y esfuerzo estimado.

Las cuatro fases se han completado. Las Fases 1 y 2 concluyeron conforme a lo planificado, y la Fase 3 se ejecutó íntegramente, incluida la ejecución del experimento con datos reales: la base de datos de referencia *Hagelskjær Microplastic Solution Library 1.1* se localizó de acceso público (Zenodo, DOI 10.5281/zenodo.17710809, licencia CC-BY-4.0) y se ejecutó la matriz experimental completa (`scripts/run_experiment.py -database Databases/Hagelskjaer -full -degradation`), validada numéricamente frente al protocolo de referencia del director (1885 comparaciones alineadas, idéntico al criterio de validación acordado). La Fase 4 cerró la redacción de los capítulos de resultados, discusión y conclusiones a partir de estos datos reales. La Figura 4.1 muestra el cronograma del proyecto.




**Figura 4.1.** Cronograma del proyecto con sus hitos de entrega. La Fase 3, incluida la ejecución del experimento con datos reales, se completó antes de la entrega intermedia.

La memoria se ha ido redactando en paralelo a las Fases 2 y 3, para documentar cada decisión técnica cuando aún estaba fresca y no acumular toda la escritura al final.

## 4.2 Descripción de la solución, metodologías y herramientas empleadas

### 4.2.1. Visión general del pipeline

La solución es un paquete Python instalable, *microraman*, con módulos independientes que se prueban por separado y se encadenan sobre cada espectro medido. La Figura 4.2 presenta el flujo de alto nivel, desde la carga del fichero de instrumento hasta el resultado estadístico final.



**Figura 4.2.** Flujo del *pipeline* implementado en el paquete *microraman*.

### 4.2.2. Pipeline de preprocesado

El preprocesado replica paso a paso el protocolo de referencia acordado con el director del proyecto; el orden es relevante y no se altera sin justificarlo:

1. **Recorte por índice de píxel:** se conservan las columnas [220:900] de la matriz de espectros, descartando los extremos del detector.

2. **Eliminación de picos espurios (*despiking*):** método de Coca-López (Coca-López, 2024) basado en la prominencia y la anchura de los picos (`scipy.signal.find_peaks + peak_widths`); los picos con anchura por debajo de un umbral y prominencia por encima de otro se marcan como espurios y se sustituyen por interpolación lineal a partir de las muestras vecinas no marcadas. El coste sobre el conjunto completo (50.000 espectros) es de aproximadamente 2,4 segundos en un único nodo, por lo que este paso no condiciona el diseño distribuido.
3. **Acumulación:** para cada nivel  $N \in \{10000, 5000, 2000, 1000, 500, 200, 100, 50, 20, 10, 5, 2, 1\}$  se calcula la *suma directa* de los primeros  $N$  espectros (no se promedia), simulando un mayor tiempo de integración del instrumento.
4. **Corrección de línea base:** se aplica `airPLS` (Zhang et al., 2010) (biblioteca `pybaselines`) al espectro *ya acumulado*, nunca antes de acumular, y se resta la línea base estimada.
5. **Recorte final por número de onda:** se restringe a la ventana  $2800\text{--}3100\text{ cm}^{-1}$  (rango real resultante:  $2800,51\text{--}3099,11\text{ cm}^{-1}$ ).

La equivalencia numérica de esta implementación con el protocolo de referencia del director se comprobó punto a punto sobre los espectros reales mediante el script `scripts/validate_vs_notebook.py`: la diferencia máxima absoluta obtenida es 0.

#### 4.2.3. Métricas de similitud espectral

Se implementan siete métricas en el módulo `microraman.metrics`, como funciones vectorizables que devuelven siempre una *similitud* (un valor mayor indica mayor parecido), transformando a similitud las que son originalmente distancias:

- **Coseno:**  $s_{\cos} = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$ .
- **Pearson:** correlación lineal entre  $\mathbf{a}$  y  $\mathbf{b}$  (Rodgers & Nicewander, 1988), invariante a desplazamientos aditivos de la línea base.
- **Spearman:** correlación de Pearson calculada sobre los rangos; captura relaciones monótonas no lineales.
- **SAM** (*Spectral Angle Mapper*) (Kruse et al., 1993):  $s_{\text{SAM}} = 1 - \theta / \pi$ , con  $\theta = \arccos(s_{\cos})$ .
- **HQI** (*Hit Quality Index*):  $s_{\text{HQI}} = s_{\cos}^2$ , estándar en librerías comerciales de espectroscopía.
- **Euclídea y Manhattan:** distancias  $L_2$  y  $L_1$  sobre los vectores normalizados, transformadas a similitud mediante  $s = 1 / (1 + d)$ ; la normalización previa evita que la métrica dependa de la intensidad absoluta, que crece con la acumulación.

#### 4.2.4. Protocolo de matching

El motor de *matching* está implementado por partida doble: `microraman.matching` (`pandas/NumPy`, versión de referencia) y `microraman.matching_spark` (`PySpark`), verificadas entre sí sobre datos sintéticos con resultado idéntico. Para cada combinación de polímero

medido y nivel de acumulación: (1) se recorta cada espectro de la base de datos de referencia al rango medido y se descartan los que no solapan lo suficiente; (2) se interpola el espectro medido al eje de cada espectro de la base de datos por separado, sin extrapolar; (3) se calcula la similitud con cada métrica y se ordena de forma descendente, conservando el top-4 por combinación.

#### 4.2.5. Arquitectura Big Data

El volumen del problema proviene de la combinatoria  $\text{polímero} \times \text{nivel de acumulación} \times \text{métrica} \times \text{espectro}$  de la base de datos de referencia, que crece al añadir bases de datos de referencia más amplias. El motor distribuido (`matching_spark`) paraleliza el producto  $\text{polímero} \times \text{nivel}$  sobre los *executors* mediante un *broadcast* de la base de datos completa, de modo que los *executors* no necesitan tener instalado el paquete. El script `scripts/benchmark_spark_scaling.py` mide el *speedup* frente al número de núcleos y frente al motor pandas de un solo nodo; para cargas pequeñas el sobre coste de Spark domina, y el beneficio de distribuir aparece al escalar el número de espectros de referencia y el número de métricas, lo que delimita cuándo conviene el motor distribuido frente al secuencial.

#### 4.2.6. Análisis estadístico

Se contrasta si existen diferencias significativas entre métricas en su capacidad de identificar el polímero correcto al degradar la calidad del espectro. El diseño es de medidas repetidas: cada bloque es una combinación  $\text{polímero} \times \text{nivel de calidad}$ , y dentro de cada bloque cada métrica produce un valor. Como variable respuesta se emplea el rango que la métrica asigna al polímero correcto (`truth_rank`), independiente de la escala de cada métrica:

- **Contraste ómnibus:** test de Friedman (no paramétrico, medidas repetidas).
- **Tamaño del efecto:**  $W$  de Kendall.
- **Post-hoc:** test de Wilcoxon de rangos con signo para cada par de métricas, con corrección de Holm–Bonferroni.

Como comprobación de robustez, el mismo análisis se repite sustituyendo la acumulación por una degradación controlada del espectro más limpio de cada polímero (ruido gaussiano a una SNR objetivo, deriva de línea base y submuestreo; módulo `microraman.degradation`), usando la SNR como eje de calidad independiente. Un *ranking* de métricas coherente entre ambos mecanismos refuerza la fiabilidad de las conclusiones.

#### 4.2.7. Decisiones técnicas y su justificación

El proyecto pivotó respecto al anteproyecto (ADR-004). La arquitectura inicial, con ingesta mediante Apache Kafka y clasificación con los modelos preentrenados de Open Specy, se sustituyó por la comparación empírica de métricas de similitud frente a la degradación de calidad. El director y yo acordamos el cambio por dos razones: la pregunta nueva no estaba

respondida en la literatura, y era abordable con los datos reales disponibles. La Tabla 4.2 sintetiza las decisiones vigentes y su justificación.

| Decisión                                                                        | Alternativas consideradas                           | consi- | Justificación                                                                                                                                                                          |
|---------------------------------------------------------------------------------|-----------------------------------------------------|--------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Motor distribuido: Apache Spark (PySpark)                                       | Dask, Ray                                           |        | Madurez y ecosistema; API de DataFrame/RDD adecuada para paralelizar por bloques independientes (polímero $\times$ nivel) (Armbrust et al., 2015; Zaharia et al., 2010, 2016).         |
| Diseño experimental: robustez de métricas frente a degradación (pivote ADR-004) | Clasificador entrenado envolviendo Open Specy       |        | Mayor valor científico al no existir una comparación sistemática publicada; evita depender de modelos preentrenados sobre un dominio (microplásticos) para el que no fueron ajustados. |
| Corrección de línea base: airPLS (pybaselines), tras acumular                   | IModPolyFit, corrección antes de acumular           | co-    | Coincide con el protocolo de referencia validado con el director; aplicarla antes de acumular distorsiona la suma.                                                                     |
| Verificación cruzada pandas/Spark                                               | Confiar únicamente en la implementación distribuida |        | Permite detectar errores de paralelización comparando resultados idénticos sobre el mismo dato sintético antes de ejecutar con datos reales.                                           |
| Empaquetado como librería instalable (pyproject.toml) + CI (GitHub Actions)     | Scripts sueltos sin empaquetar                      |        | Reproducibilidad, facilita los 97 tests automatizados y evita regresiones al iterar el <i>pipeline</i> .                                                                               |

**Tabla 4.2.** Decisiones técnicas clave del proyecto, tras el pivote de diseño (ADR-004), y su justificación.

#### 4.2.8. Metodología de trabajo

El proyecto adopta una metodología iterativa e incremental con entregables verificables por tarea (un módulo del *pipeline*, un conjunto de pruebas, un script de validación, etc.). Las reuniones periódicas con el director del proyecto, D. Nico Coca López, sirven como control de avances, validación de decisiones técnicas y punto de origen del pivote de diseño (ADR-004), documentado en el acta correspondiente. El código se versiona en un repositorio Git privado ([github.com/Lavishmxgames/master\\_bigdata](https://github.com/Lavishmxgames/master_bigdata)), con integración continua mediante GitHub Actions que ejecuta la suite de pruebas y el análisis de estilo (*ruff*) en cada cambio. La memoria del TFM se gestiona en un repositorio Git independiente, separado del código (véase el Anexo C para la URL completa), y se redacta en paralelo al desarrollo para reflejar con fidelidad las decisiones tomadas.

#### 4.2.9. Datos del proyecto

La solución se valida con dos niveles de datos complementarios:

- **Datos reales:** 5 polímeros (PET, PP, PLA, BioPBS y ECOVIO), con 10.000 espectros Raman de integración corta por polímero en la región C–H ( $\sim 2900\text{ cm}^{-1}$ ), medidos en un equipo Renishaw (ficheros `.wdf`) y proporcionados por el director del proyecto. Cada espectro está etiquetado con su polímero real.
- **Base de datos de referencia:** el experimento emplea la *Hagelskjær Microplastic Solution Library 1.1* (Hagelskjær et al., 2025) (30 espectros de referencia: 28 polímeros y 2 minerales, formato de texto plano). No fue proporcionada por el director del proyecto, sino localizada de acceso público en Zenodo (DOI 10.5281/zenodo.17710809, licencia CC-BY-4.0) a partir de una indicación del propio director de que la biblioteca era de acceso público. Se descartó 1 espectro por solape insuficiente con la ventana medida ( $2800\text{--}3100\text{ cm}^{-1}$ ), quedando 29 espectros de referencia útiles.

### 4.3 Recursos requeridos

Los recursos utilizados en el proyecto se agrupan en técnicos, humanos y de información:

- **Técnicos:** equipo de desarrollo personal; entorno Python 3.11 con *stack open-source* (NumPy, SciPy, pandas, PySpark, pybaselines, renishawWiRE, ramanchada2, pytest, ruff, Git); integración continua con GitHub Actions; editor LaTeX para la redacción de la memoria; gestor bibliográfico (Zotero).
- **Humanos:** autor del TFM (Jesús Baeza Anguiano) como responsable técnico y de redacción; director del proyecto (Nico Coca López) como supervisor científico, autor del protocolo de referencia y aportador de los espectros medidos; la base de datos de referencia empleada para el *matching* se localizó de acceso público (véase el apartado «Datos del proyecto»).
- **Información:** notebook de referencia del director del proyecto para la validación del *pipeline*; artículos científicos accesibles a través del portal bibliográfico de la Universidad Europea de Madrid.

### 4.4 Presupuesto

La Tabla 4.3 presenta la estimación económica del proyecto. El proyecto es viable en términos económicos gracias al uso exclusivo de tecnologías *open-source* y al hardware personal disponible; el coste efectivo desembolsado es nulo, y el presupuesto recoge una valoración de equivalencia en mercado.

| Tipo de coste                       | Valor estimado   | Comentarios                                                                                                   |
|-------------------------------------|------------------|---------------------------------------------------------------------------------------------------------------|
| Horas de trabajo del autor          | 300 h (~9.000 €) | Estimación a tarifa de ingeniero de datos júnior (30 €/h).                                                    |
| Supervisión (director)              | 20 h (~1.500 €)  | Estimación a tarifa de consultor (75 €/h).                                                                    |
| Equipo técnico                      | 1.200 €          | Portátil propio del autor, valor de mercado aproximado.                                                       |
| Software                            | 0 €              | Todo el <i>stack</i> es <i>open-source</i> .                                                                  |
| Acceso a bibliografía               | 0 €              | Cubierto por la suscripción de la Universidad Europea.                                                        |
| Materiales y <i>datasets</i>        | 0 €              | Espectros Raman aportados por el director; base de datos de referencia de acceso público (Zenodo, CC-BY-4.0). |
| <b>Total (equivalencia mercado)</b> | <b>~11.700 €</b> | Desembolso efectivo: 0 €.                                                                                     |

**Tabla 4.3.** Estimación del presupuesto del proyecto.

## 4.5 Viabilidad

Viabilidad técnica, temporal y económica:

- **Viabilidad técnica:** el *pipeline* de preprocesado, las siete métricas y el motor de *matching* (pandas y Spark) están implementados, probados y validados numéricamente frente al protocolo de referencia. El riesgo técnico residual es bajo: no depende de tecnología inmadura, sino de la disponibilidad de un dato externo (la base de datos de referencia).
- **Viabilidad temporal:** el riesgo más relevante identificado durante el proyecto era la dependencia de la base de datos de referencia. Se mitigó localizándola de acceso público y ejecutando el experimento completo antes de la entrega intermedia (7 sep), lo que dejó el margen restante del calendario para consolidar Resultados, Discusión y Conclusiones sobre las cifras ya obtenidas.
- **Viabilidad económica y sostenibilidad:** el coste efectivo es nulo, y la solución, al basarse en tecnologías *open-source* ampliamente adoptadas y en un paquete instalable con pruebas automatizadas, tiene un bajo coste de mantenimiento y puede reutilizarse con otras bases de datos de referencia sin rediseñar el *pipeline*.

## 4.6 Sostenibilidad del proyecto

La sostenibilidad se entiende aquí en sus tres dimensiones habituales: la ambiental, referida al efecto sobre los ecosistemas y sobre el consumo de recursos; la social, referida al acceso al conocimiento y a la salud de las poblaciones afectadas; y la económica, referida al coste de operación y a la reutilización de lo construido. El proyecto se sitúa de lleno en la primera y toca las otras dos de forma indirecta.

## **Dimensión ambiental**

El objeto de estudio es, en sí mismo, un problema ambiental. La identificación fiable de microplásticos es el paso previo a cualquier política de vigilancia o de mitigación: no se puede regular lo que no se sabe medir. El proyecto contribuye a los Objetivos de Desarrollo Sostenible de la Agenda 2030 de Naciones Unidas por dos vías. De forma directa al ODS 14 (*Vida submarina*), cuya meta 14.1 persigue reducir de forma significativa la contaminación marina, incluida la procedente de detritos plásticos; e indirectamente al ODS 6 (*Agua limpia y saneamiento*) y al ODS 12 (*Producción y consumo responsables*), que dependen de poder cuantificar la presencia de estos materiales en el medio.

Hay además un efecto ambiental derivado del propio método. Determinar qué métrica de similitud tolera mejor los espectros de integración corta permite acortar el tiempo de medida por partícula sin perder fiabilidad en la identificación. Un menor tiempo de integración se traduce en menos horas de instrumento por muestra, y por tanto en menor consumo energético del equipo Raman y mayor número de partículas analizadas con los mismos recursos.

## **Dimensión social**

La contaminación por microplásticos es también un asunto de salud pública, lo que conecta el trabajo con el ODS 3 (*Salud y bienestar*). Más allá del objeto de estudio, el enfoque adoptado tiene una consecuencia social concreta: reducir el tiempo de instrumento por muestra abarata el análisis y lo hace accesible a laboratorios con menos recursos, que son precisamente los de muchas de las regiones más expuestas a esta contaminación. En la misma línea, el proyecto se apoya en una biblioteca espectral de acceso público y publica su propio código, en coherencia con las prácticas de ciencia abierta.

## **Dimensión económica**

El coste efectivo del proyecto es nulo, al estar construido íntegramente sobre tecnologías *open-source* y hardware ya disponible (véase el apartado de presupuesto). El diseño como paquete instalable, con pruebas automatizadas e integración continua, mantiene bajo el coste de mantenimiento y permite reaprovechar el trabajo con otras bibliotecas de referencia sin rediseñar el *pipeline*.

## **Estrategias adoptadas**

De este análisis se derivan cuatro decisiones que el proyecto ya aplica y que conviene mantener en su continuación:

1. Publicar el código como paquete abierto y reutilizable, en lugar de como scripts de un solo uso, para que el esfuerzo invertido sirva a otros grupos.
2. Emplear bibliotecas espectrales de acceso público en vez de generar mediciones nuevas cuando ya existen, evitando duplicar consumo de instrumento.

3. Orientar el resultado del experimento hacia la recomendación práctica de qué métrica usar con tiempos de integración cortos, que es la vía por la que el trabajo puede reducir el gasto energético del análisis.
4. Documentar el procedimiento de forma reproducible, condición para que los resultados puedan verificarse y reutilizarse sin repetir el trabajo experimental.

## 4.7 Resultados del proyecto

Se han alcanzado los siguientes hitos técnicos, cada uno vinculado con su objetivo específico. La Fase 3 se completó íntegramente, por lo que esta sección recoge resultados obtenidos con la base de datos de referencia real, no sintética:

- **OE1 completado:** el *pipeline* de preprocesado (recorte por índice, *despiking* de Coca-López, acumulación por suma, corrección de línea base airPLS, recorte final por número de onda) está implementado en el módulo `microraman` y validado punto a punto frente al protocolo de referencia del director sobre los espectros reales, con una diferencia máxima absoluta de 0 (`scripts/validate_vs_notebook.py`).
- **OE2 completado:** las siete métricas de similitud (coseno, Pearson, Spearman, SAM, HQL, euclídea, Manhattan) están implementadas como funciones vectorizables con una convención homogénea de similitud, y cubiertas por pruebas unitarias.
- **OE3 completado, incluida la ejecución con datos reales:** la matriz experimental (polímero  $\times$  nivel de acumulación  $\times$  métrica  $\times$  espectro de referencia) se ejecutó sobre la base de datos de referencia real Hagelskjær (paralelización con PySpark disponible y verificada, aunque no necesaria a esta escala: 13195 filas en el eje de acumulación y 8120 en el de degradación, resueltas en segundos con el motor pandas). La validación numérica frente al protocolo del director se superó: **1885 comparaciones alineadas** (5 polímeros  $\times$  13 niveles  $\times$  29 espectros de referencia), idéntico al criterio acordado.
- **OE4 completado, con resultado real:** test de Friedman sobre el rango asignado al polímero correcto (`truth_rank`), restringido a los tres polímeros con verdad-terreno presente en la base de datos de referencia (véase la limitación señalada más abajo). Acumulación real:  $\chi^2 = 8,70$ ,  $p = 0,191$ ,  $W$  de Kendall = 0,037 (0/21 pares significativos tras corrección de Holm). Degradación paramétrica:  $\chi^2 = 19,35$ ,  $p = 0,0036$ ,  $W = 0,134$  (también 0/21 pares individuales significativos tras Holm).
- **OE5 completado:** el entregable visual solicitado por el director (similitud del mejor resultado frente al nivel de acumulación, una curva por métrica y por polímero) se generó con datos reales; véase la Figura 4.3.

El proyecto cuenta con 97 pruebas automatizadas en verde, ejecutadas en integración continua (GitHub Actions) en cada cambio, un paquete instalable (`pip install -e .`) y un repositorio Git separado para el código (`master_bigdata`) y otro, independiente, para esta memoria (véase el Anexo C). El experimento completo se ejecutó y se validó frente al protocolo de referencia del director.


#### 4.7.1. Resultados obtenidos

La Tabla 4.4 resume la exactitud de cada métrica en la identificación del polímero correcto (rango 1 y entre los tres primeros), restringida a los tres polímeros con verdad-terreno presente en la base de datos de referencia (PET, PLA, PP):

| Eje de calidad          | Métrica                       | Acc.@1 | Acc.@3 | Rango medio |
|-------------------------|-------------------------------|--------|--------|-------------|
| Acumulación real        | Pearson                       | 61,5 % | 79,5 % | 3,26        |
| Acumulación real        | Coseno = Euclídea = HQI = SAM | 53,8 % | 74,4 % | 4,36        |
| Acumulación real        | Manhattan                     | 41,0 % | 56,4 % | 4,28        |
| Acumulación real        | Spearman                      | 41,0 % | 69,2 % | 4,59        |
| Degradación paramétrica | Coseno = Euclídea = HQI = SAM | 87,5 % | 95,8 % | 1,25        |
| Degradación paramétrica | Pearson                       | 83,3 % | 100 %  | 1,21        |
| Degradación paramétrica | Manhattan                     | 70,8 % | 87,5 % | 1,63        |
| Degradación paramétrica | Spearman                      | 54,2 % | 100 %  | 1,75        |

**Tabla 4.4.** Exactitud de cada métrica de similitud (PET/PLA/PP), por eje de degradación de calidad.

El orden cambia según el eje. Con acumulación real gana Pearson; con degradación paramétrica, el grupo coseno, euclídea, HQI y SAM, que empata en las cuatro. Ninguna diferencia entre métricas es, sin embargo, significativa por pares tras la corrección de Holm (véase OE4). Léanse por tanto como tendencia y no como superioridad demostrada: solo tres polímeros tienen verdad-terreno disponible.




**Figura 4.3.** Similitud del mejor resultado (rango 1) frente al número de acumulaciones, una curva por métrica, una subgráfica por polímero medido. La cruz roja marca el punto en que el rango 1 deja de ser el polímero correcto.

**Punto de ruptura y *ranking* de robustez.** El punto de ruptura de una métrica para un polímero es el nivel de calidad mínimo a partir del cual el resultado de rango 1 es el polímero correcto *de forma estable* (es decir, también para todos los niveles superiores). La Tabla 4.5 lo agrega por métrica y la Figura 4.4 lo desglosa por polímero.

| Eje de calidad      | Métrica                       | Ruptura media | Mediana | Polímeros nunca identificados |
|---------------------|-------------------------------|---------------|---------|-------------------------------|
| Acumulación ( $N$ ) | Pearson                       | 101,7         | 100     | 2                             |
| Acumulación ( $N$ ) | Coseno = Euclídea = HQI = SAM | 116,7         | 100     | 2                             |
| Acumulación ( $N$ ) | Spearman                      | 110,0         | 110     | 3                             |
| Acumulación ( $N$ ) | Manhattan                     | 50,0          | 50      | 3                             |
| Degradación (SNR)   | Coseno = Euclídea = HQI = SAM | 2,7           | 2,0     | 2                             |
| Degradación (SNR)   | Pearson                       | 3,7           | 5,0     | 2                             |
| Degradación (SNR)   | Spearman                      | 3,5           | 3,5     | 3                             |
| Degradación (SNR)   | Manhattan                     | 1,0           | 1,0     | 3                             |

**Tabla 4.5.** Punto de ruptura por métrica y eje de degradación de calidad. Un valor menor indica que la métrica tolera más degradación antes de fallar; la última columna indica sobre cuántos de los cinco polímeros medidos la métrica no llega a acertar en ningún nivel.




**Figura 4.4.** Punto de ruptura por métrica y polímero en el eje de acumulación. Las celdas vacías indican que esa métrica nunca identifica correctamente ese polímero de forma estable.


Esta tabla exige una lectura cuidadosa, porque el punto de ruptura medio *no* ordena las métricas por calidad. Manhattan presenta el mejor valor aparente (50 acumulaciones), pero ese promedio se calcula únicamente sobre los dos polímeros que llega a identificar (PET y PP); en PLA nunca acierta, mientras que Pearson, con una media peor (101,7), sí resuelve los tres polímeros disponibles. Es decir, la métrica con menor punto de ruptura medio es también una de las de peor exactitud global: el promedio premia implícitamente a quien se

rinde en los casos difíciles. Por eso la exactitud de la Tabla 4.4 y la columna de polímeros nunca identificados deben leerse junto al punto de ruptura, y no de forma aislada.

**Comprobación cruzada mediante degradación paramétrica.** Para comprobar si el comportamiento observado depende del mecanismo concreto de pérdida de calidad, se repitió toda la matriz experimental sustituyendo la acumulación real por una degradación sintética (ruido gaussiano a una SNR objetivo, deriva de línea base y submuestreo) aplicada al espectro más limpio de cada polímero. Las Figuras 4.5 y 4.6 son las equivalentes de las anteriores con la SNR como eje de calidad.



**Figura 4.5.** Similitud del mejor resultado (rango 1) frente a la SNR de la degradación paramétrica, una curva por métrica y una subgráfica por polímero medido.



**Figura 4.6.** Punto de ruptura por métrica y polímero en el eje de degradación paramétrica, expresado como SNR mínima para un acierto estable.

La comparación entre ambos mecanismos arroja una coincidencia parcial: los dos coinciden en que Manhattan y Spearman son las métricas menos fiables, pero discrepan en el primer puesto (Pearson en acumulación real frente al grupo coseno/euclídea/HQI/SAM en degradación paramétrica). Las curvas de la Figura 4.5 son además más suaves y monótonas que las de la Figura 4.3. Tiene sentido: la degradación sintética solo modela la pérdida de relación señal-ruido, mientras que la acumulación real de espectros de integración corta arrastra también artefactos residuales de línea base y de eliminación de picos espurios. Esta diferencia se discute en el Capítulo 5.

**Hallazgo no anticipado:** dos de los cinco polímeros medidos (BioPBS y ECOVIO) obtienen una exactitud del 0 % con las siete métricas, en todos los niveles de calidad, incluido el de máxima calidad. La causa, verificada, no es una limitación del *pipeline* ni de las métricas: la *Hagelskjær Microplastic Solution Library 1.1* no incluye BioPBS ni ECOVIO en su catálogo de 28 polímeros y 2 minerales de referencia. Esta limitación de cobertura de la base de datos se documenta en el capítulo de Discusión y se propone como línea de trabajo futuro ampliar o combinar la base de datos de referencia para cubrir ambos polímeros.

Estos resultados se amplían en el capítulo de Discusión y se cierran en el depósito final; los números ya proceden de la ejecución real.

## Capítulo 5. DISCUSIÓN

Con el experimento ya ejecutado sobre la biblioteca de referencia real, este capítulo revisa qué funcionó del diseño, qué limita los resultados obtenidos y en qué se apartó el proyecto del planteamiento inicial.

### 5.1 Adecuación de la metodología al problema

Tras el pivote (ADR-004), el diseño experimental se ha mostrado adecuado al objetivo. Concentrar la contribución en una comparación empírica y reproducible de siete métricas de similitud, en lugar de en el desarrollo o el ajuste de un clasificador, responde a la pregunta de investigación sin depender de la disponibilidad ni de la idoneidad de modelos preentrenados para el dominio de los microplásticos.

El *pipeline* de preprocesado reproduce el protocolo de referencia del director con una diferencia máxima absoluta de 0. Es la condición de partida del trabajo: sin ella, cualquier diferencia observada entre métricas podría venir de un error de implementación y no del fenómeno medido.

### 5.2 Cambios respecto al planteamiento inicial

Respecto al anteproyecto original, el cambio de mayor calado fue el pivote de diseño del ADR-004. La arquitectura prevista al principio, con ingesta mediante Apache Kafka y clasificación con los modelos preentrenados de Open Specy sobre un flujo Spark Structured Streaming, se sustituyó por el diseño actual, centrado en la robustez de las métricas de similitud frente a la degradación de la calidad del espectro. El director y yo acordamos el cambio por tres razones:

- La literatura no recoge una comparación sistemática y a escala de las métricas de similitud habituales en *matching* espectral frente a distintos niveles de degradación de la señal. La pregunta nueva estaba sin responder; la anterior, no.
- Reutilizar los clasificadores de Open Specy como caja negra habría acotado la contribución del TFM a una capa de ingesta y orquestación, sin evidencia empírica propia sobre el problema de fondo: la fiabilidad del *matching* cuando la señal es de baja calidad.
- El diseño nuevo encaja con los datos reales disponibles (espectros Raman de cinco polímeros con distintos tiempos de integración) y con el protocolo de referencia ya validado por el director. Depender de una integración en tiempo real con los instrumentos habría añadido un riesgo de ejecución que este camino evita.

El pivote atraviesa toda la memoria: los capítulos de Objetivos, Antecedentes/Estado del arte y Desarrollo están redactados conforme al diseño vigente.

### 5.3 Limitaciones identificadas

El trabajo tiene cuatro limitaciones:

- **Cobertura incompleta de la base de datos de referencia.** Dos de los cinco polímeros medidos, BioPBS y ECOVIO, no figuran en el catálogo de la *Hagelskjær Microplastic*

*Solution Library 1.1* (28 polímeros y 2 minerales), de modo que su exactitud de identificación es del 0 % con las siete métricas y en todos los niveles de calidad. La causa está en la biblioteca, no en el *pipeline*. El análisis estadístico se restringe por ello a los tres polímeros con verdad-terreno disponible: PET, PLA y PP.

- **Tamaño muestral reducido para el análisis estadístico.** Con solo esos tres polímeros, el test de Friedman dispone de pocos bloques: 39 en acumulación y 24 en degradación. La potencia estadística queda limitada y ninguna diferencia entre métricas sobrevive la corrección de Holm por pares, pese a que la exactitud sí muestra una tendencia.
- **Escalado distribuido validado en local, no en clúster real.** La paralelización con Apache Spark se valida en un entorno de un único nodo. El despliegue en infraestructura distribuida física queda fuera del alcance de este TFM y se plantea como trabajo futuro.
- **Cinco polímeros y una única base de datos de referencia.** Las conclusiones sobre robustez se han obtenido sobre un conjunto acotado de polímeros (PET, PP, PLA, BioPBS y ECOVIO) y una sola biblioteca. Generalizarlas a otras familias de polímeros o a espectroscopía FTIR exigiría repetir el análisis, algo que el *pipeline* admite sin rediseño.

## 5.4 Interpretación de los primeros resultados

Entre los dos mecanismos de degradación el patrón no coincide del todo (Capítulo 4). Con acumulación real la métrica más robusta es Pearson; con degradación paramétrica lo son coseno, euclídea, HQI y SAM, que empatan entre sí. Los dos mecanismos sí coinciden en las dos últimas posiciones: Manhattan y Spearman.

Existe una explicación plausible para esta discrepancia. La acumulación real mejora la relación señal-ruido, pero puede dejar restos de deriva de línea base incluso después de *airPLS*. Pearson es inmune a esos desplazamientos aditivos; coseno y SAM son invariantes a escala, no a offset. Con la degradación paramétrica esa ventaja se diluye, porque allí el ruido gaussiano se añade sobre un espectro ya limpio y no queda offset que corregir.

La discrepancia tiene una consecuencia práctica: la métrica más adecuada depende del mecanismo de pérdida de calidad, y el resultado no debería trasladarse sin más a otros contextos de ruido instrumental.

## 5.5 Impacto esperado

La contribución principal es un *pipeline* completo de preprocesado, comparación de métricas y análisis estadístico, validado numéricamente, cubierto por pruebas automatizadas y ya ejecutado sobre la biblioteca de referencia real. De él sale una guía empírica de qué métrica aguanta mejor según el mecanismo de degradación, aplicable tanto al análisis de microplásticos como a otros problemas de *matching* espectral con señal degradada. Conviene mantener dos cautelas: el número de polímeros con verdad-terreno disponible es reducido, y la biblioteca de referencia no cubre todos los materiales medidos.

## Capítulo 6. CONCLUSIONES

### 6.1 Conclusiones del trabajo

Con el experimento ya ejecutado, las conclusiones son:

- El pivote del ADR-004 llevó el proyecto a una pregunta que la literatura no tenía respondida, y los datos disponibles bastaron para responderla.
- El *pipeline* de preprocesado reconstruido en el paquete `microraman` reproduce el protocolo de referencia del director con una diferencia máxima absoluta de 0. Las diferencias que se observan entre métricas vienen, por tanto, del fenómeno medido.
- Las siete métricas y el motor de *matching* están implementados en dos versiones, *pandas*/*NumPy* y *PySpark*, verificadas entre sí, y se han ejecutado ya sobre el experimento completo con la biblioteca real. La validación contra el protocolo del director alineó las 1885 comparaciones previstas.
- El ganador depende del eje de degradación: Pearson con acumulación real (61,5 % de aciertos), y el grupo coseno, euclídea, HQI y SAM con degradación paramétrica (87,5 %). Manhattan y Spearman quedan las últimas en los dos ejes. Ninguna diferencia por pares sobrevive la corrección de Holm, así que el orden debe leerse como tendencia y no como superioridad demostrada: solo tres polímeros tienen verdad-terreno disponible.
- La comprobación cruzada matiza el *ranking* en lugar de confirmarlo en bloque. Que el orden cambie según el mecanismo de degradación sugiere que la elección de métrica no es universal, sino que depende de cómo se pierda la calidad de la señal.
- Dos de los cinco polímeros medidos, BioPBS y ECOVIO, obtienen un 0 % de acierto con todas las métricas y en todos los niveles, porque la biblioteca de Hagelskjær no los recoge en su catálogo. Es un límite de la base de datos de referencia, no del método desarrollado, y se declara explícitamente en vez de omitirse.
- A la escala de esta corrida, 13195 y 8120 filas, distribuir el cómputo con Spark todavía no compensa frente a *pandas*. El punto de equilibrio exacto queda por medir.

### 6.2 Conclusiones personales

La realización de este TFM me ha dejado aprendizajes técnicos y personales que van más allá de la implementación del *pipeline*. El primero, y quizá el más estructural, es que un proyecto de Big Data no tiene por qué conservar el planteamiento tecnológico con el que se concibió, sobre todo cuando en el desarrollo surgen preguntas nuevas o se dispone de datos que permiten abordar el problema desde otro ángulo. El planteamiento inicial se apoyaba en una arquitectura de ingesta con Apache Kafka, procesamiento en Spark Structured Streaming y clasificación con los modelos preentrenados de Open Specy. Durante el desarrollo decidí, junto con el director, pivotar (ADR-004) hacia el estudio de la robustez de las métricas de similitud frente a la degradación de la calidad espectral. El cambio supuso renunciar a buena parte de la propuesta original, pero permitió centrar el trabajo en una pregunta directamente vinculada a la fiabilidad del *matching* espectral, y abordable de forma experimental con los datos ya disponibles.

Desde el punto de vista técnico, el aprendizaje más claro ha sido comprobar empíricamente que recurrir a una tecnología distribuida no garantiza, por sí solo, un mejor rendimiento. Implementé el motor de *matching* en dos versiones, una de referencia en pandas/NumPy y otra distribuida en PySpark, lo que permitió comparar ambas aproximaciones sobre el mismo problema. A la escala de los experimentos realizados — 13.195 y 8.120 filas, según el escenario — el sobrecoste de distribuir el cómputo superó la ganancia obtenida, y pandas resultó más eficiente que Spark. Esto me obligó a distinguir con más precisión entre usar una tecnología Big Data y diseñar una solución que escale de forma eficiente para el volumen real del problema: son cosas distintas, y la primera no implica la segunda.

Otro aprendizaje relevante ha sido dimensionar el peso que tiene la cobertura de los datos de referencia sobre el resultado final. Al ejecutar el experimento observé que BioPBS y ECOVIO obtenían un 0 % de acierto con las siete métricas, en todos los niveles de calidad. Mi primera hipótesis fue que el problema estaba en el *pipeline* o en las propias métricas; la revisión posterior mostró que ninguno de los dos polímeros figura en la *Hagelskjær Microplastic Solution Library 1.1*, de modo que no existía una referencia correcta contra la que identificarlos. El episodio me enseñó a no interpretar un resultado inesperado como un fallo del algoritmo antes de revisar los datos, las referencias empleadas y las condiciones del experimento: aquí la limitación estaba en la base de datos, no en el método, y acabó condicionando el alcance del análisis estadístico a los tres polímeros con verdad-terreno disponible (PET, PLA, PP).

Trabajar en un problema interdisciplinar ha sido, en sí mismo, otro aprendizaje. El proyecto no se reducía a implementar algoritmos o levantar un *pipeline*: exigía traducir un problema de identificación de microplásticos por espectroscopía Raman a un problema computacional medible y reproducible. Por eso fue crítico respetar el protocolo de preprocesado que me proporcionó el director y comprobar, paso a paso, que mi implementación lo reproducía correctamente; el *pipeline* final iguala ese protocolo de referencia con una diferencia máxima absoluta de 0, lo que permitió comparar las métricas sin que ninguna diferencia en el preprocesado contaminara la comparación. De ahí extraigo una distinción que no tenía tan clara al empezar: la validación técnica del código y la validación científica del procedimiento son necesarias las dos, pero no son lo mismo.

En retrospectiva, habría adelantado el análisis de cobertura de la biblioteca de referencia a una fase mucho más temprana del proyecto, antes de ejecutar la matriz experimental completa: saber de antemano qué polímeros contaban con una referencia válida habría permitido separar, ya en el diseño, los casos evaluables de aquellos en los que la ausencia de referencia hacía imposible la identificación. También habría diseñado desde el principio, y no a partir de una sugerencia del director casi al cierre del experimento, un análisis que no se limitara a comprobar si la referencia correcta queda en primer lugar, sino que midiera además el margen de similitud entre la referencia correcta y las incorrectas. Esa extensión queda planteada como trabajo futuro y es ejecutable directamente sobre los datos ya generados.

El propio resultado experimental me ha enseñado a leer con cautela lo que un *ranking* dice y lo que no dice. Con acumulación real, Pearson obtiene el mejor resultado; con degradación paramétrica, lo hacen conjuntamente coseno, euclídea, HQI y SAM. Pero ninguna diferencia entre métricas resulta significativa tras la corrección de Holm, así que ese orden debe leerse

como tendencia, no como una superioridad demostrada. Hacer análisis de datos no es solo producir métricas, *rankings* o *benchmarks*: es también saber hasta dónde sostienen una conclusión. Me llevo de aquí el hábito de no quedarme con un único indicador y de mirar en conjunto el tamaño de la muestra, la cobertura de los datos, el diseño experimental y la significancia estadística antes de afirmar que una métrica es mejor que otra.

A nivel profesional, el TFM me ha ayudado a precisar el tipo de problemas en los que quiero seguir formándome. Disfruté especialmente las partes de construcción del *pipeline*, transformación de datos, automatización, validación, reproducibilidad y análisis de resultados. Al mismo tiempo, el proyecto me confirmó que no me basta con construir sistemas que muevan o procesen datos: necesito entender el problema que hay detrás y tener una forma objetiva de comprobar si la solución funciona. Me sitúo, por tanto, en la intersección entre ingeniería de datos y análisis aplicado, combinando la construcción de infraestructura de procesamiento con la interpretación crítica de lo que esa infraestructura produce.

Si tuviera que resumir el aprendizaje del TFM en una sola idea, sería esta: el valor de una solución de Big Data no depende de la complejidad de su arquitectura, sino de si esa arquitectura, esos datos, esas métricas y ese diseño experimental son realmente los adecuados para responder a la pregunta planteada. El proyecto arrancó con una propuesta tecnológicamente ambiciosa y terminó mostrando que, a esta escala, pandas superaba a Spark, y que un *pipeline* técnicamente impecable no basta si los datos de referencia no permiten evaluarlo. Aprender a construir el *pipeline* fue necesario; aprender a cuestionar si el *pipeline*, los datos y el diseño eran los correctos fue, con diferencia, lo más valioso.

## Capítulo 7. FUTURAS LÍNEAS DE TRABAJO

El alcance del TFM está acotado al diseño, la implementación y la validación de un *pipeline* reproducible de comparación de métricas de similitud espectral. El trabajo deja abiertas siete líneas de continuación:

- **Cobertura de los polímeros ausentes en la biblioteca de referencia.** La ejecución del experimento reveló que BioPBS y ECOVIO no figuran en el catálogo de la *Hagelskjær Microplastic Solution Library 1.1*, de modo que identificarlos es imposible por construcción. Combinar esa biblioteca con otras públicas, o incorporar espectros de referencia propios de ambos polímeros, es lo único que permitiría cubrir los cinco materiales medidos.
- **Explotación de la región *fingerprint*.** El estudio se ha restringido a la región C–H ( $\sim 2800\text{--}3100\text{ cm}^{-1}$ ). Ya se dispone de espectros de los mismos cinco polímeros en la región *fingerprint* ( $\sim 100\text{--}1800\text{ cm}^{-1}$ ), aportados por el director del proyecto. Parametrizando la ventana de recorte del *pipeline* se podría repetir el análisis en esa región y en la combinación de ambas; la hipótesis es que la mayor riqueza de bandas discrimine mejor entre polímeros.
- **Contraste entre la referencia correcta y las incorrectas.** Hasta ahora la robustez se mide de forma binaria: el mejor resultado acierta o no acierta. Medir además la distancia entre la similitud con la referencia correcta y la que obtienen las referencias equivocadas daría una comparación más fina entre métricas, y convertiría el hallazgo de cobertura en evidencia cuantitativa. Los datos ya generados bastan para hacerlo, sin repetir el experimento.
- **Ampliación a bases de datos de referencia de mayor tamaño.** El motor de *matching* distribuido con Apache Spark escala el número de espectros de referencia sin rediseñar el *pipeline*. El paso obvio es repetir el análisis con bibliotecas públicas más amplias, como Open Specy o RRUFF, para las que `io.py` ya tiene carga multiformato.
- **Despliegue en infraestructura distribuida real.** La paralelización con PySpark se ha validado en un entorno de un único nodo. Extender la validación a un clúster multi-nodo, *on-premise* o en *cloud*, daría la curva de escalado real frente al número de *workers*.
- **Extensión a más polímeros y a espectroscopía FTIR.** Con más familias de polímeros y con espectros FTIR se vería si el *ranking* de métricas observado aquí se mantiene entre técnicas espectroscópicas distintas.
- **Incorporación de nuevas métricas o de métricas aprendidas.** El módulo `metrics.py` es un conjunto de funciones intercambiables: añadir métricas clásicas nuevas, o métricas aprendidas mediante *embeddings* entrenados, es directo, y todas quedarían comparadas bajo el mismo marco experimental y estadístico ya validado.

Con más polímeros y más bibliotecas, si las diferencias entre métricas llegan a confirmarse, los resultados dan para una publicación conjunta: hoy no existe en la literatura una guía empírica de qué métrica de similitud conviene según la calidad esperada del espectro.

## Capítulo 8. REFERENCIAS

- Araújo, C. F., Nolasco, M. M., Ribeiro, A. M. P., & Ribeiro-Claro, P. J. A. (2018). Identification of Microplastics Using Raman Spectroscopy: Latest Developments and Future Prospects. *Water Research*, 142, 426-440. <https://doi.org/10.1016/j.watres.2018.05.060>
- Armbrust, M., Xin, R. S., Lian, C., Huai, Y., Liu, D., Bradley, J. K., Meng, X., Kaftan, T., Franklin, M. J., Ghodsi, A., & Zaharia, M. (2015). Spark SQL: Relational Data Processing in Spark, 1383-1394. <https://doi.org/10.1145/2723372.2742797>
- Coca-López, N. (2024). An Intuitive and Comprehensive Approach for Spike Removal in Raman Spectroscopy. *Analytica Chimica Acta*, 1301, 342479. <https://doi.org/10.1016/j.aca.2024.342479>
- Cole, M., Lindeque, P., Halsband, C., & Galloway, T. S. (2011). Microplastics as Contaminants in the Marine Environment: A Review. *Marine Pollution Bulletin*, 62(12), 2588-2597. <https://doi.org/10.1016/j.marpolbul.2011.09.025>
- Cowger, W., Karapetrova, A., Lincoln, C., Chamas, A., Sherrod, H., Leong, N., Lasdin, K. S., Knauss, C., Teofilović, V., Arienzo, M. M., Steinmetz, Z., Primpke, S., Darjany, L., Murphy-Hagan, C., Moore, S., Moore, C., Lattin, G., Gray, A., & Kozloski, R. (2025). Open Specy 1.0: Automated (Hyper)spectroscopy for Microplastics. *Analytical Chemistry*, 97, 17345-17356. <https://doi.org/10.1021/acs.analchem.5c00962>
- Cowger, W., Steinmetz, Z., Gray, A., Munno, K., Lynch, J., Hapich, H., Primpke, S., De Frond, H., Rochman, C., & Herodotou, O. (2021). Microplastic Spectral Classification Needs an Open Source Community: Open Specy to the Rescue! *Analytical Chemistry*, 93, 7543-7548. <https://doi.org/10.1021/acs.analchem.1c00123>
- Dean, J., & Ghemawat, S. (2004). MapReduce: Simplified Data Processing on Large Clusters. *Proceedings of the 6th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, 137-150.
- Freeman, J., Vladimirov, N., Kawashima, T., Mu, Y., Sofroniew, N. J., Bennett, D. V., Rosen, J., Yang, C.-T., Looger, L. L., & Ahrens, M. B. (2014). Mapping Brain Activity at Scale with Cluster Computing. *Nature Methods*, 11(9), 941-950. <https://doi.org/10.1038/nmeth.3041>
- Hagelskjær, O., Yakovenko, N., Margenat, H., Sonke, J. E., & Le Roux, G. (2025, noviembre). Microplastic Solution Library 1.1 [Conjunto de datos, licencia CC-BY-4.0]. <https://doi.org/10.5281/zenodo.17710809>
- Hernández, L. M., Yousefi, N., & Tufenkji, N. (2017). Are There Nanoplastics in Your Personal Care Products? *Environmental Science & Technology Letters*, 4(7), 280-285. <https://doi.org/10.1021/acs.estlett.7b00187>
- Kruse, F. A., Lefkoff, A. B., Boardman, J. W., Heidebrecht, K. B., Shapiro, A. T., Barloon, P. J., & Goetz, A. F. H. (1993). The Spectral Image Processing System (SIPS) – Interactive Visualization and Analysis of Imaging Spectrometer Data. *Remote Sensing of Environment*, 44(2–3), 145-163. [https://doi.org/10.1016/0034-4257\(93\)90013-N](https://doi.org/10.1016/0034-4257(93)90013-N)
- Primpke, S., Cross, R. K., Mintenig, S. M., Simon, M., Vianello, A., Gerdts, G., & Vollertsen, J. (2020). Toward the Systematic Identification of Microplastics in the Environment: Eva-

- luation of a New Independent Software (siMPle) for Spectroscopic Analysis. *Applied Spectroscopy*, 74(9), 1127-1138. <https://doi.org/10.1177/0003702820917760>
- Primpke, S., Wirth, M., Lorenz, C., & Gerdt, G. (2018). Reference Database Design for the Automated Analysis of Microplastic Samples Based on Fourier Transform Infrared (FTIR) Spectroscopy. *Analytical and Bioanalytical Chemistry*, 410, 5131-5141. <https://doi.org/10.1007/s00216-018-1156-x>
- Rodgers, J. L., & Nicewander, W. A. (1988). Thirteen Ways to Look at the Correlation Coefficient. *The American Statistician*, 42(1), 59-66. <https://doi.org/10.1080/00031305.1988.10475524>
- Schymanski, D., Oßmann, B. E., Benismail, N., Boukerma, K., Dallmann, G., von der Esch, E., Fischer, D., Fischer, F., Gilliland, D., Glas, K., Hofmann, T., Käßler, A., Lacorte, S., Marco, J., Rakwe, M. E., Weisser, J., Witzig, C., Zumbülte, N., & Ivleva, N. P. (2021). Analysis of Microplastics in Drinking Water and Other Clean Water Samples with Raman and Infrared Spectroscopy: Minimum Requirements and Best Practices. *Analytical and Bioanalytical Chemistry*, 413, 5969-5994. <https://doi.org/10.1007/s00216-021-03498-y>
- Zaharia, M., Chowdhury, M., Franklin, M. J., Shenker, S., & Stoica, I. (2010). Spark: Cluster Computing with Working Sets. *Proceedings of the 2nd USENIX Conference on Hot Topics in Cloud Computing (HotCloud)*, 1-7.
- Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., & Stoica, I. (2016). Apache Spark: A Unified Engine for Big Data Processing. *Communications of the ACM*, 59(11), 56-65. <https://doi.org/10.1145/2934664>
- Zhang, Z.-M., Chen, S., & Liang, Y.-Z. (2010). Baseline Correction Using Adaptive Iteratively Reweighted Penalized Least Squares. *Analyst*, 135(5), 1138-1146. <https://doi.org/10.1039/b922045c>

## Capítulo 9. ANEXOS

### Anexo A. Estructura del repositorio de código

El código fuente del proyecto se mantiene en un repositorio Git privado, independiente de esta memoria: [https://github.com/Lavishmxgames/master\\_bigdata](https://github.com/Lavishmxgames/master_bigdata). Está organizado como un paquete Python instalable (`pip install -e .`), con la siguiente estructura:

```
1 src/microraman/
2   io.py                carga de .wdf y de la base de datos de referencia
3   preprocessing.py     recorte por índice, despiking, recorte por cm-1,
4       baseline airPLS
5   accumulation.py      acumulacion por suma directa (niveles N)
6   pipeline.py          orquestador end-to-end del preprocesado
7   metrics.py           7 metricas de similitud (cosine, pearson, spearman,
8       sam, hqi, euclidean, manhattan)
9   matching.py          motor de matching de referencia (pandas / NumPy)
10  matching_spark.py     motor de matching distribuido (PySpark)
11  experiment.py         matriz experimental completa + punto de ruptura
12  stats.py              Friedman, post-hoc Wilcoxon/Holm, W de Kendall
13  degradation.py        degradacion controlada (ruido, deriva, submuestreo)
14  plotting.py           entregable visual (similitud vs. acumulacion)
15 scripts/
16   validate_vs_notebook.py  validacion frente al notebook de referencia
17   benchmark_despiking.py   coste del despiking sobre el dataset completo
18   benchmark_spark_scaling.py speedup de PySpark vs. pandas y vs. nucleos
19   run_experiment.py        ejecucion end-to-end del experimento completo
20   exploratory_figures.py   figuras descriptivas de los datos reales
21 tests/                   97 pruebas automatizadas (pytest)
22 docs/                   fragmentos LaTeX de la memoria
23 notebooks/              notebook de referencia del director del
24   proyecto
```

Listing 9.1: Estructura del repositorio master\_bigdata.

### Anexo B. Reproducibilidad e integración continua

El repositorio incorpora integración continua mediante GitHub Actions, que ejecuta en cada cambio la suite de pruebas (pytest) y el análisis de estilo (ruff check y ruff format -check). El entorno se reproduce con:

```
1 py -3.11 -m venv .venv
2 .venv/Scripts/python.exe -m pip install --upgrade pip
3 .venv/Scripts/python.exe -m pip install -r requirements.txt
4 .venv/Scripts/python.exe -m pytest tests/ -v
```

Listing 9.2: Instalación del entorno y ejecución de las pruebas.

Y el experimento completo, con la base de datos de referencia ya disponible en Databases/Hagelskjaer/, se ejecuta con:

```
1 python scripts/run_experiment.py --database Databases/Hagelskjaer --full --
   degradation
```

---

Listing 9.3: Ejecución del experimento completo (matriz + estadística + degradación controlada).

## Anexo C. Repositorio de la memoria

El código fuente de esta memoria (LaTeX) se mantiene en un repositorio Git independiente del código del experimento: [https://github.com/Lavishmxgames/tfm\\_microplasticos\\_raman\\_jesus\\_baeza\\_anguiano](https://github.com/Lavishmxgames/tfm_microplasticos_raman_jesus_baeza_anguiano).