



**Universidad
Europea**

UNIVERSIDAD EUROPEA DE MADRID

ESCUELA DE ARQUITECTURA, INGENIERÍA Y DISEÑO

**MÁSTER UNIVERSITARIO EN ANÁLISIS DE DATOS MASIVOS
(BIG DATA)**

TRABAJO FIN DE MÁSTER

**ANÁLISIS A GRAN ESCALA DE LA
ROBUSTEZ DE MÉTRICAS DE SIMILITUD
ESPECTRAL FRENTE A LA DEGRADACIÓN
DE CALIDAD PARA LA IDENTIFICACIÓN DE
MICROPLÁSTICOS**

JESÚS BAEZA ANGUIANO

Dirigido por

Nico Coca López

CURSO 2025 - 2026

TÍTULO: ANÁLISIS A GRAN ESCALA DE LA ROBUSTEZ DE MÉTRICAS DE SIMILITUD ESPECTRAL FRENTE A LA DEGRADACIÓN DE CALIDAD PARA LA IDENTIFICACIÓN DE MICROPLÁSTICOS

AUTOR: JESÚS BAEZA ANGUIANO

TITULACIÓN: MÁSTER UNIVERSITARIO EN ANÁLISIS DE DATOS MASIVOS (BIG DATA)

DIRECTOR DEL PROYECTO: Nico Coca López

FECHA: Septiembre de 2026

RESUMEN

La contaminación por microplásticos es uno de los retos medioambientales más relevantes del siglo XXI. La espectroscopía Raman identifica el polímero de una partícula comparando su espectro con bibliotecas de referencia, pero la calidad de esa medida depende del tiempo de integración, y el comportamiento de las métricas de similitud frente a esa pérdida de calidad no se ha evaluado sistemáticamente y a escala.

Este trabajo desarrolla un *pipeline* reproducible y paralelizable con Apache Spark que cuantifica la robustez de siete métricas de similitud (coseno, Pearson, Spearman, *Spectral Angle Mapper* (SAM), *Hit Quality Index* (HQI), euclídea y Manhattan) frente a dos mecanismos independientes: la acumulación de espectros reales de integración corta y una degradación paramétrica por ruido. El preprocesado reproduce sin diferencia numérica el protocolo de referencia del director.

Ejecutado sobre cinco polímeros y una biblioteca pública de treinta espectros, el experimento muestra que Pearson es la métrica más robusta frente a la degradación real por acumulación (61,5 % de aciertos), mientras que coseno, euclídea, HQI y SAM lo son frente a la paramétrica (87,5 %); Manhattan y Spearman resultan sistemáticamente las menos robustas. Ninguna diferencia es significativa por pares tras corregir por comparaciones múltiples, por lo que la métrica idónea depende del mecanismo concreto de pérdida de calidad. Se detectó además que la biblioteca no cubre dos de los cinco polímeros medidos, limitación de cobertura que condiciona cualquier identificación.

Palabras clave: Big Data, Apache Spark, espectroscopía Raman, microplásticos, métricas de similitud espectral, relación señal-ruido.

ABSTRACT

Microplastic pollution is one of the most pressing environmental challenges of the 21st century. Raman spectroscopy identifies a particle's polymer by matching its spectrum against reference libraries, but the quality of that measurement depends on integration time, and the behaviour of similarity metrics under such quality loss has not been evaluated systematically and at scale.

This work develops a reproducible, Spark-parallelised pipeline that quantifies the robustness of seven similarity metrics (cosine, Pearson, Spearman, Spectral Angle Mapper (SAM), Hit Quality Index (HQI), Euclidean and Manhattan) against two independent mechanisms: the accumulation of real short-integration-time spectra, and a parametric noise-based degradation. Preprocessing reproduces the supervisor's reference protocol with zero numerical difference.

Run on five polymers and a public library of thirty reference spectra, the experiment shows that Pearson is the most robust metric against real accumulation-driven degradation (61.5 % accuracy), whereas cosine, Euclidean, HQI and SAM are the most robust against parametric degradation (87.5 %); Manhattan and Spearman are consistently the least robust. No pairwise difference is significant after correcting for multiple comparisons, so the most suitable metric depends on the specific quality-loss mechanism. The reference library was also found not to cover two of the five measured polymers, a coverage limitation that constrains any identification.

Keywords: Big Data, Apache Spark, Raman spectroscopy, microplastics, spectral similarity metrics, signal-to-noise ratio.

Índice general

RESUMEN	2
ABSTRACT	3
1. RESUMEN DEL PROYECTO	8
1.1. Contexto y justificación	8
1.2. Planteamiento del problema	8
1.3. Objetivos del proyecto	8
1.4. Resultados obtenidos	8
1.5. Estructura de la memoria	8
2. ANTECEDENTES / ESTADO DEL ARTE	9
2.1. Estado del arte	9
2.1.1. Contaminación por microplásticos y retos analíticos	9
2.1.2. Herramientas y bases de datos <i>open-source</i> de referencia	9
2.1.3. Métricas de similitud espectral	10
2.1.4. Tecnologías de procesamiento a gran escala	10
2.2. Contexto y justificación	10
2.3. Planteamiento del problema	10
3. OBJETIVOS	12
3.1. Objetivo general	12
3.2. Objetivos específicos	12
3.3. Alcance y fuera del alcance	13
3.4. Beneficios del proyecto	13
4. DESARROLLO DEL PROYECTO	15
4.1. Planificación del proyecto	15
4.2. Descripción de la solución, metodologías y herramientas empleadas	16
4.2.1. Visión general del pipeline	16
4.2.2. Pipeline de preprocesado	16
4.2.3. Métricas de similitud espectral	17
4.2.4. Protocolo de matching	17
4.2.5. Arquitectura Big Data	18
4.2.6. Análisis estadístico	18
4.2.7. Decisiones técnicas y su justificación	18
4.2.8. Metodología de trabajo	19
4.2.9. Datos del proyecto	19
4.3. Recursos requeridos	20
4.4. Presupuesto	20
4.5. Viabilidad	21
4.6. Resultados parciales del proyecto	21

4.6.1. Resultados obtenidos	22
5. DISCUSIÓN	29
5.1. Adecuación de la metodología al problema	29
5.2. Cambios respecto al planteamiento inicial	29
5.3. Limitaciones identificadas	30
5.4. Interpretación de los primeros resultados	30
5.5. Impacto esperado	31
6. CONCLUSIONES	32
6.1. Conclusiones del trabajo	32
6.2. Conclusiones personales	32
7. FUTURAS LÍNEAS DE TRABAJO	33
8. REFERENCIAS	34
REFERENCIAS	34
9. ANEXOS	36
Anexo A. Estructura del repositorio de código	36
Anexo B. Reproducibilidad e integración continua	36
Anexo C. Repositorio de la memoria	37

Índice de Figuras

4.1. Cronograma del proyecto con estado a la entrega intermedia. La Fase 3 se completó, incluida la ejecución del experimento con datos reales, antes de la fecha de esta entrega.	16
4.2. Flujo del <i>pipeline</i> implementado en el paquete <i>microraman</i>	16
4.3. Similitud del mejor resultado (rango 1) frente al número de acumulaciones, una curva por métrica, una subgráfica por polímero medido. La cruz roja marca el punto en que el rango 1 deja de ser el polímero correcto.	24
4.4. Punto de ruptura por métrica y polímero en el eje de acumulación. Las celdas vacías indican que esa métrica nunca identifica correctamente ese polímero de forma estable.	25
4.5. Similitud del mejor resultado (rango 1) frente a la SNR de la degradación paramétrica, una curva por métrica y una subgráfica por polímero medido.	27
4.6. Punto de ruptura por métrica y polímero en el eje de degradación paramétrica, expresado como SNR mínima para un acierto estable.	28

Índice de Tablas

4.1. Fases del proyecto, objetivos específicos asociados y esfuerzo estimado.	15
4.2. Decisiones técnicas clave del proyecto, tras el pivote de diseño (ADR-004), y su justificación.	19
4.3. Estimación del presupuesto del proyecto.	21
4.4. Exactitud de cada métrica de similitud (PET/PLA/PP), por eje de degradación de calidad.	23
4.5. Punto de ruptura por métrica y eje de degradación de calidad. Un valor menor indica que la métrica tolera más degradación antes de fallar; la última columna indica sobre cuántos de los cinco polímeros medidos la métrica no llega a acertar en ningún nivel.	25

Capítulo 1. RESUMEN DEL PROYECTO

1.1 Contexto y justificación

La contaminación por microplásticos es un desafío medioambiental global, y la espectroscopía Raman se ha consolidado como técnica de referencia para identificar el polímero de una partícula mediante comparación con bibliotecas espectrales (*matching*). La calidad del espectro medido depende directamente del tiempo de integración: un tiempo corto, deseable para aumentar el rendimiento de muestreo, produce espectros ruidosos y más difíciles de identificar. El comportamiento de las distintas métricas de similitud frente a esa degradación no suele evaluarse de forma sistemática y a escala.

1.2 Planteamiento del problema

¿Cómo se degrada el *matching* de un espectro Raman de microplástico contra una base de datos de referencia a medida que empeora la calidad de la señal, y qué métrica de similitud es más robusta frente a esa degradación? El proyecto combina investigación aplicada, consistente en la caracterización empírica de siete métricas frente al ruido, con desarrollo técnico: un *pipeline* de preprocesado, *matching* y análisis estadístico reproducible y paralelizable con Apache Spark.

1.3 Objetivos del proyecto

El objetivo general es evaluar a gran escala la robustez de distintas métricas de similitud espectral frente a la degradación de la calidad del espectro Raman, implementando un *pipeline* reproducible y paralelizable. Los objetivos específicos, detallados en el Capítulo 3, abarcan la validación del preprocesado frente al protocolo de referencia, la implementación de siete métricas, el diseño y paralelización de la matriz experimental, la cuantificación de la robustez mediante el punto de ruptura y un análisis estadístico, y la producción del entregable visual.

1.4 Resultados obtenidos

El *pipeline* reproduce el protocolo de referencia con diferencia numérica nula y el experimento se ha ejecutado completo sobre cinco polímeros y la biblioteca pública *Hagelskjær Microplastic Solution Library 1.1*, superando la validación numérica acordada (1885 comparaciones alineadas). Pearson resulta la métrica más robusta frente a la degradación real por acumulación (61,5 % de aciertos) y coseno, euclídea, HQI y SAM frente a la degradación paramétrica (87,5 %); Manhattan y Spearman son las menos robustas, sin diferencias significativas por pares tras la corrección de Holm. Se detectó además que la biblioteca de referencia no cubre dos de los cinco polímeros medidos.

1.5 Estructura de la memoria

La memoria se organiza en nueve capítulos. El Capítulo 2 presenta los antecedentes y el estado del arte; el Capítulo 3 detalla los objetivos; el Capítulo 4, núcleo del documento, describe la planificación, el *pipeline*, las decisiones técnicas y los resultados; el Capítulo 5 discute limitaciones y adaptaciones; los Capítulos 6 y 7 recogen conclusiones y futuras líneas de trabajo; los Capítulos 8 y 9, las referencias bibliográficas y los anexos técnicos.

Capítulo 2. ANTECEDENTES / ESTADO DEL ARTE

Este capítulo contextualiza el proyecto revisando los fundamentos de la clasificación espectral de microplásticos, las herramientas y bases de datos *open-source* existentes, las métricas de similitud espectral empleadas habitualmente en este dominio, y las tecnologías de procesamiento a gran escala sobre las que se apoya la implementación. La revisión establece la base sobre la que se identifica la pregunta de investigación que el TFM pretende responder.

2.1 Estado del arte

2.1.1. Contaminación por microplásticos y retos analíticos

Los microplásticos, definidos como partículas plásticas de tamaño inferior a 5 mm, constituyen un contaminante ubicuo en ecosistemas marinos, fluviales, terrestres y atmosféricos (Cole et al., 2011). Su persistencia y su potencial transferencia a la cadena trófica y al organismo humano (Hernández et al., 2017) han impulsado el desarrollo de métodos analíticos capaces de identificar el tipo de polímero con precisión. Las dos técnicas espectroscópicas dominantes son la espectroscopía Raman y la espectroscopía FTIR, ambas capaces de generar huellas espectrales características de cada polímero (Araújo et al., 2018; Schymanski et al., 2021). Un reto práctico compartido por ambas técnicas es que la calidad de la señal depende directamente del tiempo de integración del instrumento: un tiempo de integración corto, deseable para aumentar el rendimiento de muestreo, produce espectros con menor relación señal/ruido (SNR) y, por tanto, más difíciles de identificar correctamente.

2.1.2. Herramientas y bases de datos *open-source* de referencia

Entre las herramientas *open-source* para la identificación de microplásticos, Open Specy se ha consolidado como la plataforma de referencia comunitaria (Cowger et al., 2021). En su versión 1.0, Open Specy integra una biblioteca de más de 40.000 espectros de referencia procedentes de repositorios como RRUFF y la Raman Open Database, junto con clasificadores basados en aprendizaje automático (K-medoids y regresión logística) que alcanzan en torno al 96 % de precisión sobre su conjunto derivado (Cowger et al., 2025). siMPLe (Primpke et al., 2020) es un software independiente orientado al análisis sistemático de espectros FTIR de microplásticos, y las bases de datos de referencia como la de Primpke et al. (2018) aportan bibliotecas espectrales curadas que complementan estos esfuerzos.

Para el presente TFM, la base de datos de referencia empleada en el *matching* es la *Hagelskjær Microplastic Solution Library 1.1* (Hagelskjær et al., 2025), de acceso público en Zenodo bajo licencia CC-BY-4.0, que se compone de 30 espectros de referencia (28 polímeros y 2 minerales) en formato de texto plano.

2.1.3. Métricas de similitud espectral

La comparación entre un espectro medido y una biblioteca de referencia requiere una métrica de similitud (o distancia, transformada a similitud) que cuantifique el parecido entre ambos vectores de intensidad. En la práctica de la espectroscopía analítica y del procesamiento de señal se emplean, entre otras, la correlación de Pearson y su variante no paramétrica de Spearman, la similitud coseno y su transformación angular (*Spectral Angle Mapper*, SAM), el *Hit Quality Index* (HQI, equivalente al cuadrado de la similitud coseno y de uso extendido en librerías comerciales de espectroscopía), y las distancias L_1 (Manhattan) y L_2 (euclídea) sobre vectores normalizados. No existe un consenso único sobre qué métrica es preferible en todas las condiciones; su comportamiento relativo depende del tipo de degradación de la señal, lo que motiva una comparación empírica sistemática como la que plantea este TFM.

2.1.4. Tecnologías de procesamiento a gran escala

El paradigma Big Data ofrece mecanismos probados para el procesamiento distribuido de grandes volúmenes de datos. Apache Spark (Zaharia et al., 2010, 2016) introdujo el concepto de *Resilient Distributed Dataset* (RDD) y, posteriormente, las abstracciones *DataFrame* y *Dataset* (Armbrust et al., 2015), permitiendo operaciones en memoria sustancialmente más rápidas que los motores basados en disco para cargas iterativas. Su API en Python (PySpark) permite paralelizar operaciones vectorizadas de manera directa, lo que resulta especialmente adecuado para un problema como el de este TFM, en el que la carga computacional proviene de una combinatoria de comparaciones (polímero $\times$ nivel de calidad $\times$ métrica $\times$ espectro de referencia) fácilmente paralelizable por bloques independientes.

2.2 Contexto y justificación

El comportamiento de las métricas de similitud espectral frente al ruido no suele evaluarse de forma sistemática y a escala: los estudios que emplean una métrica concreta rara vez justifican esa elección frente a las alternativas, ni cuantifican en qué punto de degradación de la señal deja de ser fiable. Esta ausencia de una comparación empírica y reproducible es la brecha que aborda este TFM: no se trata de proponer una nueva técnica de clasificación espectral ni de mejorar una herramienta existente, sino de generar evidencia empírica, a partir de datos reales y de una matriz experimental de gran volumen, sobre qué métrica de similitud es más robusta frente a la pérdida de calidad de la señal, y de hacerlo con un *pipeline* paralelizable que permita repetir el análisis sobre bases de datos de referencia más amplias sin rediseñar el proceso.

2.3 Planteamiento del problema

A partir de la revisión anterior, la pregunta de investigación puede formularse en los siguientes términos:

¿Cómo se degrada el resultado del matching de un espectro Raman de microplástico contra una base de datos de referencia a medida que empeora la calidad de la señal medida (relación señal/ruido), y qué métrica de similitud espectral es

más robusta frente a esa degradación?

Este planteamiento orienta las decisiones técnicas del proyecto: el uso de la acumulación de espectros de integración corta como mecanismo controlado para variar la SNR, la implementación de un conjunto amplio de métricas de similitud bajo una convención homogénea, la paralelización del cómputo combinatorio con Apache Spark, y un diseño estadístico de medidas repetidas (Friedman y post-hoc de Wilcoxon con corrección de Holm–Bonferroni) que permita determinar si las diferencias observadas entre métricas son estadísticamente significativas y no atribuibles al azar.

Capítulo 3. OBJETIVOS

Este capítulo detalla los objetivos del Trabajo Fin de Máster, diferenciando entre el objetivo general que articula la contribución del proyecto y los objetivos específicos que estructuran el trabajo técnico. Se cierra con una descripción del alcance y de los beneficios esperados.

3.1 Objetivo general

El objetivo general del presente Trabajo Fin de Máster consiste en **evaluar a gran escala la robustez de distintas métricas de similitud espectral frente a la degradación de la calidad del espectro Raman en la identificación de microplásticos, e implementar para ello un *pipeline* reproducible y paralelizable** que permita ejecutar dicha evaluación sobre el volumen combinatorio de comparaciones que exige el problema (polímeros $\times$ niveles de calidad $\times$ métricas $\times$ espectros de referencia).

Se trata de un proyecto de carácter mixto: combina una componente de investigación aplicada, al caracterizar empíricamente el comportamiento de siete métricas de similitud frente al ruido espectral, con una componente de ingeniería de datos centrada en la construcción de un *pipeline* de preprocesado, matching y análisis estadístico validado, reproducible y paralelizable con Apache Spark.

3.2 Objetivos específicos

Los objetivos específicos derivan del objetivo general y han servido de guía para organizar las fases del proyecto. La numeración **OE1–OE5** se utiliza de forma transversal en el Capítulo 4 para rastrear la correspondencia entre tareas, código y objetivos.

- **OE1. Implementar y validar un *pipeline* de preprocesado espectral** (recorte por índice, eliminación de picos espurios, acumulación por suma y corrección de línea base) equivalente al protocolo de referencia definido por el director del proyecto, y verificar dicha equivalencia de forma numérica sobre los espectros reales.
- **OE2. Implementar un conjunto de al menos siete métricas de similitud** espectral como funciones reutilizables y vectorizables, con una convención homogénea en la que un valor mayor siempre indica mayor parecido, con independencia de si la métrica original es una similitud o una distancia.
- **OE3. Diseñar y ejecutar la matriz experimental** (polímero $\times$ nivel de acumulación $\times$ métrica $\times$ espectro de la base de datos de referencia) y paralelizar su cómputo con Apache Spark, verificando la equivalencia entre el motor de referencia (*pandas/NumPy*) y el motor distribuido.
- **OE4. Cuantificar la robustez de cada métrica** frente a la degradación de la calidad espectral mediante el concepto de *punto de ruptura* (el número mínimo de acumulaciones a partir del cual el primer resultado del *matching* es el polímero correcto de forma estable) y un análisis estadístico de las diferencias entre métricas (test de Friedman, tamaño del efecto y comparaciones post-hoc por pares).
- **OE5. Producir el entregable visual solicitado por el director del proyecto** (similitud del mejor resultado frente al nivel de acumulación, con una curva por métrica y por

polímero) y derivar de él una guía empírica de qué métrica conviene emplear según la calidad esperada del espectro.

3.3 Alcance y fuera del alcance

La delimitación del alcance es fundamental para garantizar la viabilidad en el plazo previsto.

Se incluye en el alcance:

- La implementación y validación numérica del *pipeline* de preprocesado frente al protocolo de referencia del director del proyecto.
- La implementación de las siete métricas de similitud y del motor de *matching*, en su versión de referencia (*pandas*) y en su versión distribuida (PySpark).
- El diseño de la matriz experimental completa y del análisis estadístico asociado (test de Friedman, tamaño del efecto de Kendall y post-hoc de Wilcoxon con corrección de Holm–Bonferroni).
- Un mecanismo de comprobación cruzada mediante degradación controlada de la señal (ruido, deriva de línea base y submuestreo) como segundo eje de calidad independiente de la acumulación.
- La ejecución del experimento completo y la generación del entregable visual, ya realizada con la base de datos de referencia real (Hagelskjær Microplastic Solution Library 1.1, de acceso público).

Queda fuera del alcance, por las razones justificadas en el anteproyecto aprobado y en el diseño experimental acordado con el director:

- El desarrollo de nuevas métricas de similitud. Se comparan siete métricas ya establecidas en la literatura y en la práctica de la espectroscopía analítica, no se propone ninguna nueva.
- El entrenamiento de modelos de aprendizaje automático para la clasificación espectral. El proyecto compara métricas de similitud directa, no clasificadores entrenados.
- El despliegue en infraestructura distribuida real (*cluster* multi-nodo o *cloud*). La paralelización con Apache Spark se valida en un entorno local; el despliegue distribuido físico se plantea como trabajo futuro.

3.4 Beneficios del proyecto

El proyecto aporta beneficios tanto a la comunidad científica dedicada al análisis de microplásticos como al ámbito de la ingeniería de datos aplicada a la química analítica:

- **Guía empírica y reproducible** sobre qué métrica de similitud espectral resulta más robusta frente a la degradación de la calidad de la señal, útil para quien deba decidir un criterio de *matching* en condiciones de tiempo de integración limitado.
- **Pipeline validado y reutilizable**, verificado punto a punto frente al protocolo de referencia, que puede aplicarse a otros conjuntos de espectros Raman de microplásticos sin modificaciones sustanciales.
- **Escalado horizontal del cómputo de similitud**, mediante una implementación en Apache Spark equivalente y verificada frente a la referencia en *pandas*, que permite extender el análisis a bases de datos de referencia de mayor tamaño sin rediseñar el

pipeline.

- **Comprobación cruzada metodológica**, al repetir el análisis con un mecanismo de degradación controlada independiente de la acumulación real, lo que refuerza la fiabilidad de las conclusiones frente a un único mecanismo de generación de ruido.
- **Valor metodológico y docente**: el proyecto sirve como caso de estudio de aplicación de tecnologías de procesamiento a gran escala a un problema científico concreto, con un diseño experimental y estadístico documentado y reproducible.

Capítulo 4. DESARROLLO DEL PROYECTO

Este capítulo constituye el núcleo técnico de la memoria. Se describen la planificación real del proyecto, la solución implementada, las metodologías y herramientas empleadas, los recursos requeridos, el presupuesto estimado, el análisis de viabilidad y los resultados parciales obtenidos a la fecha de esta entrega intermedia.

4.1 Planificación del proyecto

La planificación parte de la estructura en cuatro fases aprobada en el anteproyecto, con una dedicación estimada total de 300 horas. Tras el pivote de diseño documentado en el ADR-004 (véase el apartado de decisiones técnicas), el contenido de cada fase se reformuló en torno al nuevo experimento de robustez de métricas, pero la estructura temporal se mantuvo. La Tabla 4.1 resume las fases, su vinculación con los objetivos específicos (OE) y el esfuerzo asignado.

Fase	OE	Tareas principales	Horas
Fase 1. Análisis y estado del arte (abril–mayo 2026)	OE1	Revisión bibliográfica, análisis de Open Specy, selección de <i>stack</i> , definición del protocolo de referencia junto con el director	40
Fase 2. Diseño e implementación (mayo–agosto 2026)	OE1, OE2, OE3	Reconstrucción del <i>pipeline</i> de preprocesado, implementación de las siete métricas, motor de <i>matching</i> pandas/Spark, suite de pruebas y CI	120
Fase 3. Ejecución del experimento y validación (agosto–septiembre 2026)	OE3, OE4, OE5	Ejecución de la matriz experimental completa con la base de datos de referencia, análisis estadístico, entregable visual	60
Fase 4. Redacción y cierre (agosto–septiembre 2026)	—	Redacción de memoria, revisión, defensa	80

Tabla 4.1. Fases del proyecto, objetivos específicos asociados y esfuerzo estimado.

A la fecha de esta entrega intermedia (septiembre de 2026), las Fases 1 y 2 están completadas al 100 % y la Fase 3 se ha completado íntegramente, incluida la ejecución del experimento con datos reales: la base de datos de referencia *Hagelskjær Microplastic Solution Library 1.1* se localizó de acceso público (Zenodo, DOI 10.5281/zenodo.17710809, licencia CC-BY-4.0) y se ejecutó la matriz experimental completa (`scripts/run_experiment.py -database Databases/Hagelskjaer -full -degradation`), validada numéricamente frente al protocolo de referencia del director (1885 comparaciones alineadas, idéntico al criterio de validación acordado). La Fase 4 avanza con la redacción de los capítulos de resultados, discusión y conclusiones a partir de estos datos reales. La Figura 4.1 muestra el cronograma y el estado actual.




Figura 4.1. Cronograma del proyecto con estado a la entrega intermedia. La Fase 3 se completó, incluida la ejecución del experimento con datos reales, antes de la fecha de esta entrega.

La línea de redacción de la memoria avanza en paralelo a las Fases 2 y 3, lo que permite consolidar decisiones técnicas a medida que se toman y reducir la carga final de documentación.

4.2 Descripción de la solución, metodologías y herramientas empleadas

4.2.1. Visión general del pipeline

La solución se articula como un paquete Python instalable, *microraman*, organizado en módulos independientes y probados por separado, que se ejecutan de forma encadenada sobre cada espectro medido. La Figura 4.2 presenta el flujo de alto nivel, desde la carga del fichero de instrumento hasta el resultado estadístico final.




Figura 4.2. Flujo del *pipeline* implementado en el paquete *microraman*.

4.2.2. Pipeline de preprocesado

El preprocesado replica paso a paso el protocolo de referencia acordado con el director del proyecto; el orden es relevante y no se altera sin justificarlo:

1. **Recorte por índice de píxel:** se conservan las columnas [220:900] de la matriz de espectros, descartando los extremos del detector.

2. **Eliminación de picos espurios (*despiking*):** método de Coca-López basado en la prominencia y la anchura de los picos (`scipy.signal.find_peaks + peak_widths`); los picos con anchura por debajo de un umbral y prominencia por encima de otro se marcan como espurios y se sustituyen por interpolación lineal a partir de las muestras vecinas no marcadas. El coste sobre el conjunto completo (50.000 espectros) es de aproximadamente 2,4 segundos en un único nodo, por lo que este paso no condiciona el diseño distribuido.
3. **Acumulación:** para cada nivel $N \in \{10000, 5000, 2000, 1000, 500, 200, 100, 50, 20, 10, 5, 2, 1\}$ se calcula la *suma directa* de los primeros N espectros (no se promedia), simulando un mayor tiempo de integración del instrumento.
4. **Corrección de línea base:** se aplica `airPLS` (biblioteca `pybaselines`) al espectro *ya acumulado*, nunca antes de acumular, y se resta la línea base estimada.
5. **Recorte final por número de onda:** se restringe a la ventana $2800\text{--}3100\text{ cm}^{-1}$ (rango real resultante: $2800,51\text{--}3099,11\text{ cm}^{-1}$).

La equivalencia numérica de esta implementación con el protocolo de referencia del director se comprobó punto a punto sobre los espectros reales mediante el script `scripts/validate_vs_notebook.py`: la diferencia máxima absoluta obtenida es 0.

4.2.3. Métricas de similitud espectral

Se implementan siete métricas en el módulo `microraman.metrics`, como funciones vectorizables que devuelven siempre una *similitud* (un valor mayor indica mayor parecido), transformando a similitud las que son originalmente distancias:

- **Coseno:** $s_{\cos} = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|}$.
- **Pearson:** correlación lineal entre $\mathbf{a}$ y $\mathbf{b}$, invariante a desplazamientos aditivos de la línea base.
- **Spearman:** correlación de Pearson calculada sobre los rangos; captura relaciones monótonas no lineales.
- **SAM (*Spectral Angle Mapper*):** $s_{\text{SAM}} = 1 - \theta/\pi$, con $\theta = \arccos(s_{\cos})$.
- **HQI (*Hit Quality Index*):** $s_{\text{HQI}} = s_{\cos}^2$, estándar en librerías comerciales de espectroscopía.
- **Euclídea y Manhattan:** distancias L_2 y L_1 sobre los vectores normalizados, transformadas a similitud mediante $s = 1/(1 + d)$; la normalización previa evita que la métrica dependa de la intensidad absoluta, que crece con la acumulación.

4.2.4. Protocolo de matching

El motor de *matching* está implementado por partida doble: `microraman.matching` (pandas/-NumPy, versión de referencia) y `microraman.matching_spark` (PySpark), verificadas entre sí sobre datos sintéticos con resultado idéntico. Para cada combinación de polímero medido

y nivel de acumulación: (1) se recorta cada espectro de la base de datos de referencia al rango medido y se descartan los que no solapan lo suficiente; (2) se interpola el espectro medido al eje de cada espectro de la base de datos por separado, sin extrapolar; (3) se calcula la similitud con cada métrica y se ordena de forma descendente, conservando el top-4 por combinación.

4.2.5. Arquitectura Big Data

El volumen del problema proviene de la combinatoria $\text{polímero} \times \text{nivel de acumulación} \times \text{métrica} \times \text{espectro}$ de la base de datos de referencia, que crece al añadir bases de datos de referencia más amplias. El motor distribuido (`matching_spark`) paraleliza el producto $\text{polímero} \times \text{nivel}$ sobre los *executors* mediante un *broadcast* de la base de datos completa, de modo que los *executors* no necesitan tener instalado el paquete. El script `scripts/benchmark_spark_scaling.py` mide el *speedup* frente al número de núcleos y frente al motor pandas de un solo nodo; para cargas pequeñas el sobre coste de Spark domina, y el beneficio de distribuir aparece al escalar el número de espectros de referencia y el número de métricas, lo que delimita cuándo conviene el motor distribuido frente al secuencial.

4.2.6. Análisis estadístico

Se contrasta si existen diferencias significativas entre métricas en su capacidad de identificar el polímero correcto al degradar la calidad del espectro. El diseño es de medidas repetidas: cada bloque es una combinación $\text{polímero} \times \text{nivel de calidad}$, y dentro de cada bloque cada métrica produce un valor. Como variable respuesta se emplea el rango que la métrica asigna al polímero correcto (`truth_rank`), independiente de la escala de cada métrica:

- **Contraste ómnibus:** test de Friedman (no paramétrico, medidas repetidas).
- **Tamaño del efecto:** W de Kendall.
- **Post-hoc:** test de Wilcoxon de rangos con signo para cada par de métricas, con corrección de Holm–Bonferroni.

Como comprobación de robustez, el mismo análisis se repite sustituyendo la acumulación por una degradación controlada del espectro más limpio de cada polímero (ruido gaussiano a una SNR objetivo, deriva de línea base y submuestreo; módulo `microraman.degradation`), usando la SNR como eje de calidad independiente. Un ranking de métricas coherente entre ambos mecanismos refuerza la fiabilidad de las conclusiones.

4.2.7. Decisiones técnicas y su justificación

El proyecto sufrió un pivote de diseño respecto al anteproyecto original, documentado como ADR-004: la arquitectura inicial (ingesta con Apache Kafka y clasificación mediante los modelos preentrenados de Open Specy) se sustituyó por el diseño actual, centrado en la comparación empírica de métricas de similitud frente a la degradación de calidad, tras acordar con el director del proyecto que esta pregunta tenía mayor valor científico y era más viable

de responder con los datos reales disponibles. La Tabla 4.2 sintetiza las decisiones vigentes y su justificación.

Decisión	Alternativas consideradas	consi-	Justificación
Motor distribuido: Apache Spark (PySpark)	Dask, Ray		Madurez y ecosistema; API de DataFrame/RDD adecuada para paralelizar por bloques independientes (polímero $\times$ nivel) (Armbrust et al., 2015; Zaharia et al., 2010, 2016).
Diseño experimental: robustez de métricas frente a degradación (pivote ADR-004)	Clasificador entrenado envolviendo Open Specy		Mayor valor científico al no existir una comparación sistemática publicada; evita depender de modelos preentrenados sobre un dominio (microplásticos) para el que no fueron ajustados.
Corrección de línea base: airPLS (pybaselines), tras acumular	IModPolyFit, corrección antes de acumular	co-	Coincide con el protocolo de referencia validado con el director; aplicarla antes de acumular distorsiona la suma.
Verificación cruzada pandas/Spark	Confiar únicamente en la implementación distribuida		Permite detectar errores de paralelización comparando resultados idénticos sobre el mismo dato sintético antes de ejecutar con datos reales.
Empaquetado como librería instalable (pyproject.toml) + CI (GitHub Actions)	Scripts sueltos sin empaquetar		Reproducibilidad, facilita los 97 tests automatizados y evita regresiones al iterar el pipeline.

Tabla 4.2. Decisiones técnicas clave del proyecto, tras el pivote de diseño (ADR-004), y su justificación.

4.2.8. Metodología de trabajo

El proyecto adopta una metodología iterativa e incremental con entregables verificables por tarea (un módulo del *pipeline*, un conjunto de pruebas, un script de validación, etc.). Las reuniones periódicas con el director del proyecto, D. Nico Coca López, sirven como control de avances, validación de decisiones técnicas y punto de origen del pivote de diseño (ADR-004), documentado en el acta correspondiente. El código se versiona en un repositorio Git privado (github.com/Lavishmxgames/master_bigdata), con integración continua mediante GitHub Actions que ejecuta la suite de pruebas y el análisis de estilo (*ruff*) en cada cambio. La memoria del TFM se gestiona en un repositorio Git independiente, separado del código (véase el Anexo C para la URL completa), y se redacta en paralelo al desarrollo para reflejar con fidelidad las decisiones tomadas.

4.2.9. Datos del proyecto

La solución se valida con dos niveles de datos complementarios:

- **Datos reales:** 5 polímeros (PET, PP, PLA, BioPBS y ECOVIO), con 10.000 espectros Raman de integración corta por polímero en la región C–H ($\sim 2900\text{ cm}^{-1}$), medidos en un equipo Renishaw (ficheros `.wdf`) y proporcionados por el director del proyecto. Cada espectro está etiquetado con su polímero real.
- **Base de datos de referencia:** el experimento emplea la *Hagelskjær Microplastic Solution Library 1.1* (Hagelskjær et al., 2025) (30 espectros de referencia: 28 polímeros y 2 minerales, formato de texto plano). No fue proporcionada por el director del proyecto, sino localizada de acceso público en Zenodo (DOI 10.5281/zenodo.17710809, licencia CC-BY-4.0) a partir de una indicación del propio director de que la biblioteca era de acceso público. Se descartó 1 espectro por solape insuficiente con la ventana medida ($2800\text{--}3100\text{ cm}^{-1}$), quedando 29 espectros de referencia útiles.

4.3 Recursos requeridos

Los recursos utilizados en el proyecto se agrupan en técnicos, humanos y de información:

- **Técnicos:** equipo de desarrollo personal; entorno Python 3.11 con *stack open-source* (NumPy, SciPy, pandas, PySpark, pybaselines, renishawWiRE, ramanchada2, pytest, ruff, Git); integración continua con GitHub Actions; editor LaTeX para la redacción de la memoria; gestor bibliográfico (Zotero).
- **Humanos:** autor del TFM (Jesús Baeza Anguiano) como responsable técnico y de redacción; director del proyecto (Nico Coca López) como supervisor científico, autor del protocolo de referencia y aportador de los espectros medidos; la base de datos de referencia empleada para el *matching* se localizó de acceso público (véase el apartado «Datos del proyecto»).
- **Información:** notebook de referencia del director del proyecto para la validación del *pipeline*; artículos científicos accesibles a través del portal bibliográfico de la Universidad Europea de Madrid.

4.4 Presupuesto

La Tabla 4.3 presenta la estimación económica del proyecto. El proyecto es viable en términos económicos gracias al uso exclusivo de tecnologías *open-source* y al hardware personal disponible; el coste efectivo desembolsado es nulo, y el presupuesto recoge una valoración de equivalencia en mercado.

Tipo de coste	Valor estimado	Comentarios
Horas de trabajo del autor	300 h (~9.000 €)	Estimación a tarifa de ingeniero de datos júnior (30 €/h).
Supervisión (director)	20 h (~1.500 €)	Estimación a tarifa de consultor (75 €/h).
Equipo técnico	1.200 €	Portátil propio del autor, valor de mercado aproximado.
Software	0 €	Todo el <i>stack</i> es <i>open-source</i> .
Acceso a bibliografía	0 €	Cubierto por la suscripción de la Universidad Europea.
Materiales y <i>datasets</i>	0 €	Espectros Raman aportados por el director; base de datos de referencia de acceso público (Zenodo, CC-BY-4.0).
Total (equivalencia mercado)	~11.700 €	Desembolso efectivo: 0 €.

Tabla 4.3. Estimación del presupuesto del proyecto.

4.5 Viabilidad

El análisis de viabilidad se aborda en tres ejes:

- **Viabilidad técnica:** el *pipeline* de preprocesado, las siete métricas y el motor de *matching* (pandas y Spark) están implementados, probados y validados numéricamente frente al protocolo de referencia. El riesgo técnico residual es bajo: no depende de tecnología inmadura, sino de la disponibilidad de un dato externo (la base de datos de referencia).
- **Viabilidad temporal:** el riesgo más relevante identificado durante el proyecto era la dependencia de la base de datos de referencia. Se mitigó localizándola de acceso público y ejecutando el experimento completo antes de esta entrega intermedia (7 sep), lo que deja el margen completo hasta la entrega final (21 sep) para pulir la redacción de Resultados, Discusión y Conclusiones con las cifras reales ya obtenidas.
- **Viabilidad económica y sostenibilidad:** el coste efectivo es nulo, y la solución, al basarse en tecnologías *open-source* ampliamente adoptadas y en un paquete instalable con pruebas automatizadas, tiene un bajo coste de mantenimiento y puede reutilizarse con otras bases de datos de referencia sin rediseñar el *pipeline*.

4.6 Resultados parciales del proyecto

A la fecha de esta entrega intermedia se han alcanzado los siguientes hitos técnicos, cada uno vinculado con su objetivo específico. A diferencia de la planificación original, la Fase 3 se completó íntegramente, por lo que esta sección ya incluye resultados obtenidos con la base de datos de referencia real (no sintética):

- **OE1 completado:** el *pipeline* de preprocesado (recorte por índice, *despiking* de Coca-López, acumulación por suma, corrección de línea base airPLS, recorte final por número de onda) está implementado en el módulo *microraman* y validado punto a punto

frente al protocolo de referencia del director sobre los espectros reales, con una diferencia máxima absoluta de 0 (`scripts/validate_vs_notebook.py`).

- **OE2 completado:** las siete métricas de similitud (coseno, Pearson, Spearman, SAM, HQL, euclídea, Manhattan) están implementadas como funciones vectorizables con una convención homogénea de similitud, y cubiertas por pruebas unitarias.
- **OE3 completado, incluida la ejecución con datos reales:** la matriz experimental (polímero $\times$ nivel de acumulación $\times$ métrica $\times$ espectro de referencia) se ejecutó sobre la base de datos de referencia real Hagelskjær (paralelización con PySpark disponible y verificada, aunque no necesaria a esta escala: 13195 filas en el eje de acumulación y 8120 en el de degradación, resueltas en segundos con el motor pandas). La validación numérica frente al protocolo del director se superó: **1885 comparaciones alineadas** (5 polímeros $\times$ 13 niveles $\times$ 29 espectros de referencia), idéntico al criterio acordado.
- **OE4 completado, con resultado real:** test de Friedman sobre el rango asignado al polímero correcto (`truth_rank`), restringido a los tres polímeros con verdad-terreno presente en la base de datos de referencia (véase la limitación señalada más abajo). Acumulación real: $\chi^2 = 8,70$, $p = 0,191$, W de Kendall = 0,037 (0/21 pares significativos tras corrección de Holm). Degradación paramétrica: $\chi^2 = 19,35$, $p = 0,0036$, $W = 0,134$ (también 0/21 pares individuales significativos tras Holm).
- **OE5 completado:** el entregable visual solicitado por el director (similitud del mejor resultado frente al nivel de acumulación, una curva por métrica y por polímero) se generó con datos reales; véase la Figura 4.3.

En conjunto, el proyecto cuenta con 97 pruebas automatizadas en verde, ejecutadas en integración continua (GitHub Actions) en cada cambio, un paquete instalable (`pip install -e .`) y un repositorio Git separado para el código (`master_bigdata`) y otro, independiente, para esta memoria (véase el Anexo C). El experimento completo se ejecutó y validó antes de esta entrega intermedia.

4.6.1. Resultados obtenidos

La Tabla 4.4 resume la exactitud de cada métrica en la identificación del polímero correcto (rango 1 y entre los tres primeros), restringida a los tres polímeros con verdad-terreno presente en la base de datos de referencia (PET, PLA, PP):

Eje de calidad	Métrica	Acc.@1	Acc.@3	Rango medio
Acumulación real	Pearson	61,5 %	79,5 %	3,26
Acumulación real	Coseno = Euclídea = HQI = SAM	53,8 %	74,4 %	4,36
Acumulación real	Manhattan	41,0 %	56,4 %	4,28
Acumulación real	Spearman	41,0 %	69,2 %	4,59
Degradación paramétrica	Coseno = Euclídea = HQI = SAM	87,5 %	95,8 %	1,25
Degradación paramétrica	Pearson	83,3 %	100 %	1,21
Degradación paramétrica	Manhattan	70,8 %	87,5 %	1,63
Degradación paramétrica	Spearman	54,2 %	100 %	1,75

Tabla 4.4. Exactitud de cada métrica de similitud (PET/PLA/PP), por eje de degradación de calidad.

Pearson resulta la métrica más robusta frente a la acumulación real de espectros de baja integración, mientras que coseno, euclídea, HQI y SAM (empatadas) lo son frente a la degradación paramétrica controlada. Ninguna diferencia entre métricas resulta, sin embargo, estadísticamente significativa por pares tras la corrección de Holm (véase OE4 más arriba), por lo que estos resultados deben interpretarse como una tendencia y no como una superioridad confirmada, condicionada además por el tamaño muestral reducido (solo tres polímeros con verdad-terreno disponible).




Figura 4.3. Similitud del mejor resultado (rango 1) frente al número de acumulaciones, una curva por métrica, una subgráfica por polímero medido. La cruz roja marca el punto en que el rango 1 deja de ser el polímero correcto.

Punto de ruptura y ranking de robustez. El punto de ruptura de una métrica para un polímero es el nivel de calidad mínimo a partir del cual el resultado de rango 1 es el polímero correcto *de forma estable* (es decir, también para todos los niveles superiores). La Tabla 4.5 lo agrega por métrica y la Figura 4.4 lo desglosa por polímero.

Eje de calidad	Métrica	Ruptura media	Mediana	Polímeros nunca identificados
Acumulación (N)	Pearson	101,7	100	2
Acumulación (N)	Coseno = Euclídea = HQI = SAM	116,7	100	2
Acumulación (N)	Spearman	110,0	110	3
Acumulación (N)	Manhattan	50,0	50	3
Degradación (SNR)	Coseno = Euclídea = HQI = SAM	2,7	2,0	2
Degradación (SNR)	Pearson	3,7	5,0	2
Degradación (SNR)	Spearman	3,5	3,5	3
Degradación (SNR)	Manhattan	1,0	1,0	3

Tabla 4.5. Punto de ruptura por métrica y eje de degradación de calidad. Un valor menor indica que la métrica tolera más degradación antes de fallar; la última columna indica sobre cuántos de los cinco polímeros medidos la métrica no llega a acertar en ningún nivel.




Figura 4.4. Punto de ruptura por métrica y polímero en el eje de acumulación. Las celdas vacías indican que esa métrica nunca identifica correctamente ese polímero de forma estable.

Esta tabla exige una lectura cuidadosa, porque el punto de ruptura medio *no* ordena las métricas por calidad. Manhattan presenta el mejor valor aparente (50 acumulaciones), pero ese promedio se calcula únicamente sobre los dos polímeros que llega a identificar (PET y PP); en PLA nunca acierta, mientras que Pearson, con una media peor (101,7), sí resuelve los tres polímeros disponibles. Es decir, la métrica con menor punto de ruptura medio es también una de las de peor exactitud global: el promedio premia implícitamente a quien se

rinde en los casos difíciles. Por eso la exactitud de la Tabla 4.4 y la columna de polímeros nunca identificados deben leerse junto al punto de ruptura, y no de forma aislada.

Comprobación cruzada mediante degradación paramétrica. Para comprobar si el comportamiento observado depende del mecanismo concreto de pérdida de calidad, se repitió toda la matriz experimental sustituyendo la acumulación real por una degradación sintética (ruido gaussiano a una SNR objetivo, deriva de línea base y submuestreo) aplicada al espectro más limpio de cada polímero. Las Figuras 4.5 y 4.6 son las equivalentes de las anteriores con la SNR como eje de calidad.




Figura 4.5. Similitud del mejor resultado (rango 1) frente a la SNR de la degradación paramétrica, una curva por métrica y una subgráfica por polímero medido.




Figura 4.6. Punto de ruptura por métrica y polímero en el eje de degradación paramétrica, expresado como SNR mínima para un acierto estable.

La comparación entre ambos mecanismos arroja una coincidencia parcial: los dos coinciden en que Manhattan y Spearman son las métricas menos fiables, pero discrepan en el primer puesto (Pearson en acumulación real frente al grupo coseno/euclídea/HQI/SAM en degradación paramétrica). Las curvas de la Figura 4.5 son además notablemente más suaves y monótonas que las de la Figura 4.3, lo que resulta coherente con el hecho de que la degradación sintética modela únicamente la pérdida de relación señal-ruido, mientras que la acumulación real de espectros de integración corta arrastra también artefactos residuales de línea base y de eliminación de picos espurios. Esta diferencia se discute en el Capítulo 5.

Hallazgo no anticipado: dos de los cinco polímeros medidos (BioPBS y ECOVIO) obtienen una exactitud del 0 % con las siete métricas, en todos los niveles de calidad, incluido el de máxima calidad. La causa, verificada, no es una limitación del *pipeline* ni de las métricas: la *Hagelskjær Microplastic Solution Library 1.1* no incluye BioPBS ni ECOVIO en su catálogo de 28 polímeros y 2 minerales de referencia. Esta limitación de cobertura de la base de datos se documenta en el capítulo de Discusión y se propone como línea de trabajo futuro ampliar o combinar la base de datos de referencia para cubrir ambos polímeros.

La redacción detallada de estos resultados, junto con su discusión completa, se pulirá para la entrega final del proyecto; los datos aquí presentados proceden ya de la ejecución real, no de una base de datos sintética.

Capítulo 5. DISCUSIÓN

Este capítulo recoge las reflexiones sobre el trabajo realizado, las limitaciones observadas y las adaptaciones efectuadas respecto al planteamiento inicial, ya con los resultados del experimento completo ejecutado con la base de datos de referencia real. Su redacción se pulirá para la entrega final, pero los hallazgos que recoge proceden ya de datos reales, no sintéticos.

5.1 Adecuación de la metodología al problema

El diseño experimental adoptado tras el pivote (ADR-004) se ha mostrado adecuado al objetivo del proyecto. Concentrar la contribución en una comparación empírica y reproducible de siete métricas de similitud, en lugar de en el desarrollo o ajuste de un clasificador, permite responder a la pregunta de investigación sin depender de la disponibilidad ni de la idoneidad de modelos preentrenados para el dominio de microplásticos. La validación punto a punto del *pipeline* de preprocesado frente al protocolo de referencia del director (diferencia máxima absoluta de 0) confirma que la reconstrucción del *pipeline* en el paquete `microraman` es fiel al método científico acordado, condición necesaria para que cualquier conclusión posterior sobre robustez de métricas sea atribuible al fenómeno estudiado y no a un error de implementación.

5.2 Cambios respecto al planteamiento inicial

El cambio más relevante respecto al anteproyecto original es el pivote de diseño documentado en el ADR-004: la arquitectura inicialmente prevista, basada en ingesta con Apache Kafka y clasificación mediante los modelos preentrenados de Open Specy sobre un flujo Spark Structured Streaming, se sustituyó por el diseño actual, centrado en la robustez de métricas de similitud frente a la degradación de la calidad del espectro. Este cambio se acordó con el director del proyecto porque:

- No existe en la literatura una comparación sistemática y a escala de las métricas de similitud habituales en *matching* espectral frente a distintos niveles de degradación de la señal, lo que dota al nuevo planteamiento de mayor valor científico que la propuesta original.
- Reutilizar los clasificadores de Open Specy como caja negra habría acotado la contribución del TFM a una capa de ingesta y orquestación, sin aportar evidencia empírica propia sobre el problema de fondo (la fiabilidad del *matching* en condiciones de baja calidad de señal).
- El nuevo diseño es compatible con los datos reales disponibles (espectros Raman de cinco polímeros con distintos tiempos de integración) y con el protocolo de referencia ya validado por el director, lo que reduce el riesgo de ejecución frente a depender de una integración en tiempo real con instrumentos.

Este pivote se refleja de forma transversal en toda la memoria: los capítulos de Objetivos, Antecedentes/Estado del arte y Desarrollo se han redactado ya conforme al diseño vigente.

5.3 Limitaciones identificadas

El trabajo presenta varias limitaciones que es honesto reconocer en esta entrega intermedia:

- **Cobertura incompleta de la base de datos de referencia.** La limitación más relevante identificada tras ejecutar el experimento es que dos de los cinco polímeros medidos (BioPBS y ECOVIO) no están en el catálogo de la *Hagelskjær Microplastic Solution Library 1.1* (28 polímeros y 2 minerales), por lo que su exactitud de identificación es del 0 % con las siete métricas, en todos los niveles de calidad. No es un fallo del *pipeline* ni de las métricas desarrolladas, sino una limitación de cobertura de la base de datos de referencia empleada; el análisis estadístico se restringe correctamente a los tres polímeros con verdad-terreno disponible (PET, PLA, PP).
- **Tamaño muestral reducido para el análisis estadístico.** Al restringir el análisis a los tres polímeros con verdad-terreno en la base de datos, el test de Friedman dispone de pocos bloques (39 en acumulación, 24 en degradación), lo que limita la potencia estadística: ninguna diferencia entre métricas sobrevive la corrección de Holm por pares, pese a existir una tendencia observable en `accuracy@1/@3`.
- **Escalado distribuido validado en local, no en clúster real.** La paralelización con Apache Spark se valida en un entorno de un único nodo; el despliegue en infraestructura distribuida física queda fuera del alcance de este TFM y se plantea como trabajo futuro.
- **Cinco polímeros y una única base de datos de referencia.** Las conclusiones sobre robustez de métricas se obtendrán sobre un conjunto acotado de polímeros (PET, PP, PLA, BioPBS y ECOVIO) y una única biblioteca de referencia; su generalización a otras familias de polímeros o a espectroscopía FTIR requeriría repetir el análisis, si bien el *pipeline* está diseñado para admitirlo sin rediseño.

5.4 Interpretación de los primeros resultados

Los resultados obtenidos (Capítulo 4, Resultados parciales) muestran un patrón no completamente coincidente entre los dos mecanismos de degradación de calidad estudiados: Pearson es la métrica más robusta frente a la acumulación real de espectros de baja integración, mientras que coseno, euclídea, HQI y SAM son las más robustas frente a la degradación paramétrica controlada (ruido gaussiano sintético). Ambos mecanismos coinciden, en cambio, en que Manhattan y Spearman son consistentemente las métricas menos robustas. Una posible explicación es que la acumulación real, además de mejorar la relación señal-ruido, puede dejar restos de deriva de línea base pese a la corrección `airPLS`, frente a lo cual Pearson es invariante por construcción (al ser invariante a desplazamientos aditivos), mientras que coseno y SAM son invariantes a escala pero no a offset, una propiedad que pesa menos cuando la degradación es puramente un ruido gaussiano añadido sobre un espectro ya limpio, como en la degradación paramétrica. Esta discrepancia sugiere que la elección de métrica más adecuada puede depender del mecanismo concreto de pérdida de calidad, y no debería generalizarse sin más a otros contextos de ruido instrumental.

5.5 Impacto esperado

La principal contribución del proyecto, al cierre de esta entrega intermedia, es un *pipeline* de preprocesado, comparación de métricas y análisis estadístico, validado numéricamente, cubierto por pruebas automatizadas y ya ejecutado con la base de datos de referencia real. El resultado obtenido, una guía empírica sobre qué métrica de similitud espectral resulta más robusta según el mecanismo de degradación de la calidad de la señal, tiene valor tanto para la comunidad de análisis de microplásticos como para cualquier aplicación de *matching* espectral en condiciones de señal degradada, si bien su generalización debe matizarse por el tamaño muestral reducido y por la cobertura incompleta de la base de datos de referencia empleada.

Capítulo 6. CONCLUSIONES

Nota: este capítulo tiene carácter preliminar en la entrega intermedia. Se redactará su versión definitiva en la entrega final, una vez ejecutado el experimento completo con la base de datos de referencia real y obtenidos los resultados de robustez de métricas.

6.1 Conclusiones del trabajo

En el estado actual del proyecto pueden formularse las siguientes conclusiones parciales:

- El pivote de diseño hacia una comparación empírica de siete métricas de similitud frente a la degradación de la calidad espectral (ADR-004) constituye una pregunta de investigación con mayor valor científico que la propuesta original y se ha confirmado viable con los datos reales disponibles.
- El *pipeline* de preprocesado reconstruido en el paquete *microraman* reproduce de forma exacta (diferencia máxima absoluta de 0) el protocolo de referencia validado por el director del proyecto, lo que garantiza que las conclusiones sobre robustez de métricas son atribuibles al fenómeno estudiado.
- Las siete métricas de similitud y el motor de *matching*, en su versión de referencia (*pandas/NumPy*) y en su versión distribuida (*PySpark*), están implementados, probados, verificados entre sí y **ya ejecutados sobre el experimento completo** con la base de datos de referencia real (*Hagelskjær Microplastic Solution Library 1.1*, localizada de acceso público), con validación numérica superada (1885 comparaciones alineadas).
- De forma preliminar (véase el Capítulo 4 para el detalle numérico): Pearson resulta la métrica más robusta frente a la acumulación real de espectros de baja integración, mientras que coseno, euclídea, HQI y SAM lo son frente a la degradación paramétrica controlada; ninguna diferencia por pares es estadísticamente significativa tras la corrección de Holm. Se ha detectado además que la base de datos de referencia no cubre dos de los cinco polímeros medidos (BioPBS y ECOVIO), lo que limita el alcance de estas conclusiones a los tres polímeros con verdad-terreno disponible (PET, PLA, PP).

Las conclusiones definitivas, con la interpretación completa del punto de ruptura de cada métrica por polímero y de los resultados del análisis estadístico, se pulirán en la memoria final; los datos numéricos que las sustentan ya proceden de la ejecución real del experimento, no de una base de datos sintética.

6.2 Conclusiones personales

Se completará en la entrega final del TFM.

Capítulo 7. FUTURAS LÍNEAS DE TRABAJO

Aunque el alcance del TFM está acotado al diseño, implementación y validación de un *pipeline* reproducible de comparación de métricas de similitud espectral, el trabajo abre varias líneas de continuación claramente identificadas:

- **Ampliación a bases de datos de referencia de mayor tamaño.** El motor de *matching* distribuido con Apache Spark está diseñado para escalar el número de espectros de referencia sin rediseñar el *pipeline*; una línea natural es repetir el análisis con bibliotecas públicas más amplias (por ejemplo, Open Specy o RRUFF), para las que ya existe soporte de carga multiformato en el módulo `io.py`.
- **Cobertura de polímeros ausentes en la biblioteca de referencia.** La ejecución del experimento reveló que dos de los cinco polímeros medidos (BioPBS y ECOVIO) no figuran en el catálogo de la *Hagelskjær Microplastic Solution Library 1.1*, por lo que su identificación es imposible por construcción. Combinar esta biblioteca con otras públicas, o incorporar espectros de referencia propios de ambos polímeros, permitiría evaluar la robustez de las métricas sobre el conjunto completo de materiales medidos.
- **Explotación de la región *fingerprint*.** El estudio se ha restringido a la región C–H ($\sim 2800\text{--}3100\text{ cm}^{-1}$). Se dispone ya de espectros de los mismos cinco polímeros en la región *fingerprint* ($\sim 100\text{--}1800\text{ cm}^{-1}$), aportados por el director del proyecto; parametrizar la ventana de recorte del *pipeline* permitiría repetir el análisis en esa región y en la combinación de ambas, con la hipótesis de que la mayor riqueza de bandas mejore la discriminación entre polímeros.
- **Despliegue en infraestructura distribuida real.** La paralelización con PySpark se ha validado en un entorno de un único nodo. Extender la validación a un clúster multi-nodo (*on-premise* o *cloud*) permitiría cuantificar el escalado real del motor de *matching* frente al número de *workers*.
- **Extensión a más polímeros y a espectroscopía FTIR.** El análisis de robustez de métricas se ha diseñado sobre cinco polímeros y espectros Raman; ampliarlo a más familias de polímeros y a espectros FTIR permitiría comprobar si el ranking de métricas observado se mantiene entre técnicas espectroscópicas.
- **Publicación de los hallazgos como guía de referencia.** Si el análisis estadístico confirma diferencias significativas y consistentes entre métricas, los resultados podrían formalizarse como una guía empírica de referencia (o una contribución a la literatura) sobre qué métrica de similitud conviene emplear según la calidad esperada del espectro, un vacío identificado en la revisión del estado del arte.
- **Incorporación de nuevas métricas o de métricas aprendidas.** El módulo `metrics.py` está diseñado como un conjunto de funciones intercambiables; añadir nuevas métricas clásicas o métricas aprendidas (por ejemplo, mediante *embeddings* entrenados) sería directo y permitiría compararlas bajo el mismo marco experimental y estadístico ya validado.

Capítulo 8. REFERENCIAS

- Araújo, C. F., Nolasco, M. M., Ribeiro, A. M. P., & Ribeiro-Claro, P. J. A. (2018). Identification of Microplastics Using Raman Spectroscopy: Latest Developments and Future Prospects. *Water Research*, 142, 426-440. <https://doi.org/10.1016/j.watres.2018.05.060>
- Armbrust, M., Xin, R. S., Lian, C., Huai, Y., Liu, D., Bradley, J. K., Meng, X., Kaftan, T., Franklin, M. J., Ghodsi, A., & Zaharia, M. (2015). Spark SQL: Relational Data Processing in Spark, 1383-1394. <https://doi.org/10.1145/2723372.2742797>
- Cole, M., Lindeque, P., Halsband, C., & Galloway, T. S. (2011). Microplastics as Contaminants in the Marine Environment: A Review. *Marine Pollution Bulletin*, 62(12), 2588-2597. <https://doi.org/10.1016/j.marpolbul.2011.09.025>
- Cowger, W., Karapetrova, A., Lincoln, C., Chamas, A., Sherrod, H., Leong, N., Lasdin, K. S., Knauss, C., Teofilović, V., Arienzo, M. M., Steinmetz, Z., Primpke, S., Darjany, L., Murphy-Hagan, C., Moore, S., Moore, C., Lattin, G., Gray, A., & Kozloski, R. (2025). Open Specy 1.0: Automated (Hyper)spectroscopy for Microplastics. *Analytical Chemistry*, 97, 17345-17356. <https://doi.org/10.1021/acs.analchem.5c00962>
- Cowger, W., Steinmetz, Z., Gray, A., Munno, K., Lynch, J., Hapich, H., Primpke, S., De Frond, H., Rochman, C., & Herodotou, O. (2021). Microplastic Spectral Classification Needs an Open Source Community: Open Specy to the Rescue! *Analytical Chemistry*, 93, 7543-7548. <https://doi.org/10.1021/acs.analchem.1c00123>
- Hagelskjær, O., Yakovenko, N., Margenat, H., Sonke, J. E., & Le Roux, G. (2025, noviembre). Microplastic Solution Library 1.1 [Conjunto de datos, licencia CC-BY-4.0]. <https://doi.org/10.5281/zenodo.17710809>
- Hernández, L. M., Yousefi, N., & Tufenkji, N. (2017). Are There Nanoplastics in Your Personal Care Products? *Environmental Science & Technology Letters*, 4(7), 280-285. <https://doi.org/10.1021/acs.estlett.7b00187>
- Primpke, S., Cross, R. K., Mintenig, S. M., Simon, M., Vianello, A., Gerdts, G., & Vollertsen, J. (2020). Toward the Systematic Identification of Microplastics in the Environment: Evaluation of a New Independent Software (siMPle) for Spectroscopic Analysis. *Applied Spectroscopy*, 74(9), 1127-1138. <https://doi.org/10.1177/0003702820917760>
- Primpke, S., Wirth, M., Lorenz, C., & Gerdts, G. (2018). Reference Database Design for the Automated Analysis of Microplastic Samples Based on Fourier Transform Infrared (FTIR) Spectroscopy. *Analytical and Bioanalytical Chemistry*, 410, 5131-5141. <https://doi.org/10.1007/s00216-018-1156-x>
- Schymanski, D., Oßmann, B. E., Benismail, N., Boukerma, K., Dallmann, G., von der Esch, E., Fischer, D., Fischer, F., Gilliland, D., Glas, K., Hofmann, T., Käßler, A., Lacorte, S., Marco, J., Rakwe, M. E., Weisser, J., Witzig, C., Zumbülte, N., & Ivleva, N. P. (2021). Analysis of Microplastics in Drinking Water and Other Clean Water Samples with Raman and Infrared Spectroscopy: Minimum Requirements and Best Practices. *Analytical and Bioanalytical Chemistry*, 413, 5969-5994. <https://doi.org/10.1007/s00216-021-03498-y>

-
- Zaharia, M., Chowdhury, M., Franklin, M. J., Shenker, S., & Stoica, I. (2010). Spark: Cluster Computing with Working Sets. *Proceedings of the 2nd USENIX Conference on Hot Topics in Cloud Computing (HotCloud)*, 1-7.
- Zaharia, M., Xin, R. S., Wendell, P., Das, T., Armbrust, M., Dave, A., & Stoica, I. (2016). Apache Spark: A Unified Engine for Big Data Processing. *Communications of the ACM*, 59(11), 56-65. <https://doi.org/10.1145/2934664>

Capítulo 9. ANEXOS

Anexo A. Estructura del repositorio de código

El código fuente del proyecto se mantiene en un repositorio Git privado, independiente de esta memoria: https://github.com/Lavishmxgames/master_bigdata. Está organizado como un paquete Python instalable (`pip install -e .`), con la siguiente estructura:

```
1 src/microraman/
2   io.py                carga de .wdf y de la base de datos de referencia
3   preprocessing.py     recorte por índice, despiking, recorte por cm-1,
4       baseline airPLS
5   accumulation.py      acumulacion por suma directa (niveles N)
6   pipeline.py          orquestador end-to-end del preprocesado
7   metrics.py           7 metricas de similitud (cosine, pearson, spearman,
8       sam, hqi, euclidean, manhattan)
9   matching.py          motor de matching de referencia (pandas / NumPy)
10  matching_spark.py     motor de matching distribuido (PySpark)
11  experiment.py         matriz experimental completa + punto de ruptura
12  stats.py              Friedman, post-hoc Wilcoxon/Holm, W de Kendall
13  degradation.py        degradacion controlada (ruido, deriva, submuestreo)
14  plotting.py           entregable visual (similitud vs. acumulacion)
15 scripts/
16   validate_vs_notebook.py  validacion frente al notebook de referencia
17   benchmark_despiking.py   coste del despiking sobre el dataset completo
18   benchmark_spark_scaling.py speedup de PySpark vs. pandas y vs. nucleos
19   run_experiment.py        ejecucion end-to-end del experimento completo
20   exploratory_figures.py   figuras descriptivas de los datos reales
21 tests/                   97 pruebas automatizadas (pytest)
22 docs/                   fragmentos LaTeX de la memoria
23 notebooks/              notebook de referencia del director del
24   proyecto
```

Listing 9.1: Estructura del repositorio master_bigdata.

Anexo B. Reproducibilidad e integración continua

El repositorio incorpora integración continua mediante GitHub Actions, que ejecuta en cada cambio la suite de pruebas (pytest) y el análisis de estilo (ruff check y ruff format -check). El entorno se reproduce con:

```
1 py -3.11 -m venv .venv
2 .venv/Scripts/python.exe -m pip install --upgrade pip
3 .venv/Scripts/python.exe -m pip install -r requirements.txt
4 .venv/Scripts/python.exe -m pytest tests/ -v
```

Listing 9.2: Instalación del entorno y ejecución de las pruebas.

Y el experimento completo, con la base de datos de referencia ya disponible en Databases/Hagelskjaer/, se ejecuta con:

```
1 python scripts/run_experiment.py --database Databases/Hagelskjaer --full --
   degradation
```

Listing 9.3: Ejecución del experimento completo (matriz + estadística + degradación controlada).

Anexo C. Repositorio de la memoria

El código fuente de esta memoria (LaTeX) se mantiene en un repositorio Git independiente del código del experimento: https://github.com/Lavishmxgames/tfm_microplasticos_raman_jesus_baeza_anguiano.